

DIGITALIZAÇÃO DA CADERNETA DA GESTANTE

Uma Arquitetura de IA Responsável para Apoio à Decisão Clínica no Pré-Natal

Aluno: Lucas Zegrine Duarte

Orientador: Humberto Torres Marques Neto

PUC MG - ICEI - CC - Trabalho de Conclusão de Curso




SUMÁRIO

- 06** CONTEXTO E PROBLEMA
- 08** PROPOSTA E ARQUITETURA RESPONSÁVEL
- 09** DEMONSTRAÇÃO DA PLATAFORMA
- 10** METODOLOGIA DE AVALIAÇÃO
- 11** RESULTADOS E LIMITAÇÕES
- 12** CONCLUSÃO E TRABALHOS FUTUROS



PROBLEMA

DOCUMENTAÇÃO PRÉ-NATAL FRAGMENTADA
AUMENTA A CARGA DOCUMENTAL.



Desafios operacionais:

- Registros distribuídos entre e-SUS e Caderneta da Gestante
- Consulta a documentos e protocolos de diferentes fontes e edições
- Atenção dividida entre escuta, registro e orientação

Documentos e protocolos consultados no cuidado pré-natal



POTENCIAIS, RISCOS E CONTROLES

Riscos considerados e respectivos controles arquiteturais da proposta.

Potencial assistivo da LLM	Risco associado	Mecanismo de controle
Organizar e pré-preencher registros da consulta	Informação incorreta ou inventada no registro	Verificação humana obrigatória
Recuperar trechos relevantes de protocolos públicos	Resposta sem base documental ou alucinação	Recuperação de contexto de documentos oficiais
Gerar rascunhos de respostas e orientações contextualizadas	Confiança excessiva ou automação indevida	Agência humana, saída editável e ausência de autonomia decisória
Apoiar a consulta sem expor dados identificáveis ao modelo	Exposição de dados pessoais e sensíveis	Processamento local e mascaramento de Dados Pessoais Identificáveis (PII)



Pergunta Norteadora.

Como aplicar LLMs como apoio documental no pré-natal, com base nos protocolos públicos de saúde, mitigando riscos de alucinação e exposição de dados sensíveis?





OBJETIVOS

Especificar, implementar e avaliar uma plataforma on-premise para apoio documental ao pré-natal integrando LLMs fundamentadas via RAG, mascaramento de PII e revisão humana obrigatória para apoiar o registro e tomada de decisão clínica.

- Desenvolver um protótipo de consulta assistida, com revisão humana obrigatória.
- Mascarar e sanitizar dados pessoais brasileiros antes de inferência.
- Recuperar conhecimento via RAG sobre documentos públicos oficiais.
- Avaliar recuperação, aderência das respostas, privacidade e latência.
- Analisar trade-offs entre privacidade local, custo computacional, latência e viabilidade de implantação.

ARQUITETURA






ARQUITETURA

Diagrama DER da base de dados

MÓDULO ESCRIBA

Transcrição speech-to-text local com sanitização de dados e geração de insights durante a consulta.

Fluxo de execução



Controle de persistência

- Áudio não persistido
- Transcrição sanitizada salva após confirmação humana
- Saídas da IA permanecem editáveis pelo profissional

Diarização e acesso

- Diarização opcional com pyannote
- Rótulos de diarização editáveis

ESCOLHA DO MODELO

Triagem por viabilidade local

Modelo	Parâmetros	VRAM	Decisão
Qwen3.5 9B	9B	≈ 10,5 GB	Selecionado
Qwen3 8B	8B	≈ 10,4 GB	Compatível
Qwen3 14B	14B	≈ 16,1 GB	Descartado
GPT-OSS	20B	≈ 17,3 GB	Descartado
Modelos 27B–35B	27B–35B	≈ 24–27 GB	Inviáveis

Ambiente-alvo: RTX 5060 Ti (16 GB VRAM)
Quantização Q4

Critério: evitar offloading e preservar latência operacional

Modelos acima de ≈13GB foram descartados para evitar uso de RAM/CPU e aumento de latência na resposta

Conjunto de hyperparâmetros

LLM	VALOR
Contexto	16,384
Batch	0,9
Temperatura	0,1
Top_p	0,9

RAG	VALOR
embedding_model	nomic-embed-text
chunking_size	até 900 caracteres
max_chunks	até 6 chunks
re_rank	MMR ativado

Configuração conservadora.

METODOLOGIA DE TESTES

Benchmark automatizado com critérios de aceitação por caso.

Instrumento e Ambiente

SUÍTE DE TESTES

N = 100

90 de protocolo · 10 traps

CORPUS

17 PDFs

Documentos oficiais do MS

MÓDULOS

5 componentes


RAG - LLM - PII - STT

EXECUÇÃO LOCAL

Docker

RTX 5060 Ti · 16 GB VRAM

Processo de Conferência



Microsoft Copilot Studio Agent Evaluation

1

Test set
Conjunto de perguntas e cenários.

2

Test case
Pergunta + resposta esperada + limiar

3

Avaliação
Envia conjunto de testes e atribui fPass/Fail.

4

Evidência
Consulta resposta, critério e recursos usados.

RESULTADOS

O RAG recupera a fonte esperada com frequência, mas a geração ainda falha em critérios de protocolo.

Portanto, as saídas devem permanecer editáveis e validadas pelo profissional.

373 ms

Latência média de respostas

≈2,3 s

tempo até começar a responder

0%

0/76 entidades vazaram em frases sintéticas

Qwen3.5 9B com RAG



Hit@6 - fonte esperada entre os 6 trechos



APR - 55/96 critérios obrigatórios aprovados



TFR - 1/10 falhas em perguntas distratoras



PII - 0/76 vazamento de dados pessoais nos testes

RESULTADOS

WER: Word Error Rate.
O corpus turbo, sintético, apresentou menor erro no cenário medido.
Já CORAA revela forte dependência no domínio de saúde.

16,1%


≈1 erro a cada 6 palavras
no conjunto médico

4,4%

melhor WER observado
no corpus turbo

≈2,2 s

p50: metade das execuções
concluiu até esse tempo



16,1%

MEDICAL WER: Corpus voz humana clínica.


Julia's Data. Brazilian Portuguese Medical Audio Sample.
Hugging Face, 2026.



4,4%

TURBO WER: Áudio sintético com jargão de pré-natal

Conjunto sintético de avaliação **TTS** via pt-BR-FranciscaNeural



81,2%

CORAA WER: Corpus fala espontânea PT-BR

Cândido Júnior, et al. CORAA ASR.
<https://github.com/nilc-nlp/CORAA>, 2023.

LIMITAÇÕES

Aderência parcial de respostas

O modelo local com RAG atingiu 57,3% de aprovação nos critérios automáticos e apresentou taxa de falha de 10,0% em perguntas distratoras.

Evidência recuperada nem sempre suficiente

O phrase recall global de 47,1% indica que os trechos recuperados nem sempre continham toda a evidência necessária para satisfazer o critério de resposta.

Segurança de infraestrutura não avaliada

A topologia em contêineres foi adotada como medida de privacidade by design. Não foram realizados testes específicos de segurança de rede.

Restrição computacional local

O fluxo local com RAG apresentou latência média end-to-end de 15s depende diretamente da VRAM disponível limitando a adoção em infraestrutura de baixo custo.

Validade externa limitada

A avaliação foi realizada em ambiente controlado, sem participação de profissionais, gestantes ou uso de dados clínicos reais.

Implicação para uso

Devido aos resultados, o sistema deve permanecer assistivo, com validação humana antes da persistência de qualquer informação.

TRABALHOS FUTUROS



Validação em CPS/APS	STT e diarização	Testes com mais modelos	Mobile Health
Validação com profissionais de saúde com testes de usabilidade, carga cognitiva, tempo de consulta e aceitação de sugestões.	Testes de transcrição, identificação de participantes e tratamento de falas sobrepostas em cenários clínicos simulados.	Comparação de resultados com modelos locais maiores e modelos com Fine-tuning em corpus obstétrico PT-BR	Extensão do agente para atuação no WhatsApp com lembretes de consulta, resumo validado e conteúdo educativo por idade gestacional mediante validação profissional.

CONCLUSÃO



Arquitetura implementada

- Integração de transcrição local, RAG sobre documentos oficiais, mascaramento de PII e revisão humana.
- Processamento on-premise, reduzindo a exposição de dados sensíveis a serviços externos.

Evidências obtidas

- Hit@6 de 78% na recuperação de fontes esperadas.
- 0 vazamentos em 76 testes de PII.
- Transcrição local com WER de 16,1% no corpus médico avaliado.

Limite e implicação

- A geração ainda apresentou APR de 57,3% e falhou em 10% das perguntas distratoras.
- Portanto, o sistema deve permanecer como apoio documental, com saídas editáveis e validação humana antes da persistência no prontuário.





Foto: Nathan Dumlao / Unsplash

OBRIGADO!

Perguntas?

Aluno: Lucas Zegrine Duarte
Orientador: Humberto Torres Marques Neto
PUC Minas - ICEI - CC