

Digitalização da Caderneta da Gestante: Um Ecossistema de IA Responsável para Apoio à Decisão Clínica no Pré-Natal

Lucas Zegrine Duarte¹, Humberto Torres Marques Neto¹

¹Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Caixa Postal 1.686 – 30.535-901 – Belo Horizonte – MG – Brazil

{humberto.neto, lucas.duarte}@sga.pucminas.br

Abstract. *Clinical documentation for prenatal care in the Brazilian Unified Health System (SUS) remains fragmented between paper booklets and digital records, while generative language models raise privacy and hallucination risks when deployed in the public sector. This work describes an on-premise architecture that combines local speech-to-text (Faster-Whisper), retrieval-augmented generation over Brazilian Ministry of Health manuals (ChromaDB, local embeddings via Ollama), and a Model Context Protocol (MCP) sidecar for de-identification of personal identifiable information before model calls. A companion benchmark service reproduces the RAG pipeline for controlled experiments. The first found limitation of the system is the requirement for specialized local hardware to support acceptable inference latency.*

Resumo. *A documentação clínica do pré-natal no Sistema Único de Saúde (SUS) enfrenta fragmentação entre registros físicos e digitais, resultando em alta carga cognitiva para os profissionais. A aplicação de Modelos de Linguagem de Grande Escala (LLMs) levanta riscos de privacidade e alucinação no setor público. Este trabalho propõe uma arquitetura on-premise que integra transcrição de voz local (Faster-Whisper), Geração Aumentada por Recuperação (RAG) sobre manuais do Ministério da Saúde do Brasil, e um Model Context Protocol (MCP) para anonimização de dados sensíveis antes da inferência da Inteligência Artificial. A contribuição principal é a especificação de uma arquitetura replicável e segura. Inicialmente a limitação inerente ao sistema proposto é a dependência de hardware local específico que suporte inferência de LLMs com baixa latência.*

Palavras-chave: Cuidado pré-natal; Inteligência artificial; Sistemas de informação em saúde; Privacidade de dados; Geração Aumentada por Recuperação; IA Explicável.

1. Introdução

A Inteligência Artificial (IA) tem demonstrado potencial transformador na saúde pública, oferecendo soluções para otimização de fluxos de trabalho e suporte à decisão [Rajpurkar et al. 2022, Cabitza and colegas 2022]. No contexto do atendimento pré-natal, aplicações preditivas baseadas em aprendizado de máquina evidenciam eficácia na identificação precoce de riscos gestacionais [Xu et al. 2025, Fergus et al. 2022]. Contudo, a mortalidade e morbidade materna no Brasil permanecem como desafios de saúde

pública persistentes, frequentemente agravados por gargalos no acesso e registro adequado de dados durante a assistência [Tomasi et al. 2018, Laurenti et al. 2010].

A documentação clínica no Sistema Único de Saúde (SUS) enfrenta um cenário de fragmentação, exigindo que o profissional de saúde registre informações simultaneamente em plataformas digitais pelo e-SUS e em ferramentas físicas, como a Caderneta da Gestante. Essa dualidade impõe maior carga cognitiva durante as consultas, comprometendo o tempo de contato direto e humanizado com a paciente [Theme Filha and et al. 2014, Rajpurkar et al. 2022].

Para atenuar essa sobrecarga, o presente trabalho propõe a especificação de uma plataforma digital *on-premise* que integra transcrição de voz para texto (*Speech-to-Text*) e agentes de Inteligência Artificial baseados em Geração Aumentada por Recuperação (RAG). A ideia principal é automatizar o preenchimento de formulários clínicos durante a consulta, utilizando como referências os protocolos oficiais do Ministério da Saúde disponíveis nas cartilhas de estratificação de risco.

Complicações gestacionais e gravidez de alto risco demandam acompanhamento rigoroso

e geram impactos expressivos na infraestrutura do sistema público de saúde [Roshanzamir and Taghavi 2025].

Para otimizar esse monitoramento, modelos generativos têm sido propostos como assistentes virtuais clínicos.

No entanto, a implantação irrestrita de Modelos de Linguagem de Grande Escala (LLMs) em cenários públicos depara-se com duas barreiras críticas: o risco de exposição de dados sensíveis (*Personally Identifiable Information* - PII) [OWASP GenAI Security Project 2023, Atheniense and Marques-Neto 2024], violando normativas como a Lei Geral de Proteção de Dados (LGPD), e a propensão à geração de condutas clínicas fabricadas, por alucinações [OWASP GenAI Security Project 2023, Atheniense and Marques-Neto 2024].

Portanto, a justificativa técnica e científica deste projeto fundamenta-se na necessidade de investigar arquiteturas que assegurem a governança absoluta dos dados através de infraestruturas locais e isoladas; pretendem minimizar o impacto de alucinação nas sugestões de IA utilizando-se de *Recover Augmented Generation* (RAG) para indexar e fundamentar o agente em protocolos e informações de referência verdadeira (*ground truth*) baseada nas cartilhas de estratificação de risco; adotem do padrão *Model Context Protocol* (MCP) aliado a estratégias operacionais de *human-in-the-loop* busca garantir que os profissionais da saúde operem o ecossistema com transparência, mitigando assertivamente o risco de viés algorítmico e alucinação [Anthropic et al. 2024, Governo Federal do Brasil 2025] e utilize de sistemas de mascaramento de dados pessoais sensíveis (PII) antes de enviar para o modelo de IA por meio de anonimização e pseudonimização antes de qualquer tratamento de dados clínicos no pipeline.

A pesquisa baseia-se na seguinte pergunta norteadora: *Como especificar e arquitetar um sistema de apoio ao pré-natal que reduza a carga cognitiva do profissional de saúde, garantindo privacidade local de dados (LGPD) e mitigando alucinações sem eximir a validação médica da tomada de decisão?*

Para responder a este problema geral, três subquestões operacionais são investigadas:

- Como construir uma topologia de rede isolada em contêineres que impossibilite o vazamento de áudio ou dados textuais sensíveis para a internet pública?
- Como mitigar situações em que o profissional confia excessivamente nas sugestões algorítmicas devido à fadiga por meio de um fluxo *human-in-the-loop*?
- Como avaliar a qualidade do modelo e da recuperação de informações na ausência de validação inicial em campo por um Comitê de Ética em Pesquisa?

Este projeto possui como objetivo geral especificar e arquitetar uma plataforma digital *on-premise* para apoio ao pré-natal, integrando Inteligência Artificial fundamentada via RAG para reduzir a carga cognitiva do atendimento, com foco em explicabilidade, privacidade e alinhamento às diretrizes da LGPD.

Para atingir o objetivo geral, delineiam-se os seguintes objetivos específicos:

1. Revisar literatura sobre IA Responsável em saúde pública, com ênfase em explicabilidade, viés, privacidade e governança;
2. Formalizar requisitos e histórias de usuário focadas na interação entre profissionais de saúde e o sistema nas necessidades do cuidado da gestante.
3. Propor e documentar uma topologia de implantação replicável em *Docker*.
4. Descrever o pipeline de consulta envolvendo transcrição de fala para texto (*STT*), *MCP*, RAG e processamento pelo modelo de linguagem.
5. Desenvolver e descrever estratégias locais de mitigação de riscos de privacidade através da anonimização de identificadores sensíveis.
6. Definir fluxos mitigadores de alucinação utilizando calibragem de hiperparâmetros na inferência, RAG e exigência estrita de revisão humana dos registros gerados.
7. Prevenir ameaças de prompt injection pro meio de saneamento das entrada do usuario e prompts estruturados com separação explícita de ordens.

2. Referencial Teórico

2.1. IA Responsável e Governança em Saúde

A IA Responsável (RAI) transcende a ética teórica ao propor a operacionalização de princípios de transparência e justiça na engenharia de software [Shneiderman 2021, Dignum 2022]. Na saúde, essa necessidade é suprida por frameworks como o *FUTURE-AI*, que estabelece diretrizes para a implantação de sistemas confiáveis [Lekadir et al. 2023], e o *FAIR-AI*, focado na revisão contínua de modelos clínicos [Lekadir and et al. 2022].

No cenário brasileiro, a governança deve alinhar-se à Lei Geral de Proteção de Dados (LGPD) e a frameworks institucionais que buscam mitigar riscos regulatórios e fragmentações normativas no setor público [Atheniense and Marques-Neto 2024, Governo Federal do Brasil 2025].

2.2. LLMs e RAG na Saúde Pública

Modelos de Linguagem de Grande Escala (LLMs) oferecem novas possibilidades para a análise de prontuários. Contudo, devido ao risco de alucinações em contextos clínicos, a técnica de *Retrieval-Augmented Generation* (RAG) é empregada para restringir a base de conhecimento do modelo aos Manuais Técnicos de Pré-Natal do Ministério da Saúde.

3. Materiais

Nesta seção, são detalhados os componentes que estruturam o sistema, incluindo os requisitos de *hardware* para execução local, os *frameworks* de desenvolvimento, as bases de dados utilizadas e as ferramentas de Inteligência Artificial implementadas.

3.1. Hardware

Para viabilizar a arquitetura *on-premise*, o hardware foi dimensionado para atender aos requisitos de inferência do *Large Language Model* (LLM) clínico.

Tabela 1. Especificações de hardware utilizado.

Componente	Especificação
CPU	Intel Core i7-14700K
GPU	Nvidia RTX 5060ti 16gb
RAM	Vengeance 2x 16GB DDR5 6000MHz
PSU	750W Gold Corsair
Motherboard	Asus ROG STRIX Z790 ROG MAXIMUS HERO

O poder computacional mínimo depende primariamente da quantidade de VRAM dedicada para alocar simultaneamente o motor RAG e os modelos de agente *LLM* clínico.

3.2. Software e Frameworks

O ambiente adota *TypeScript* como linguagem principal. O *backend* foi desenvolvido em *Node.js* utilizando o micro-*framework* Hono para orquestração assíncrona da API. O *frontend* foi estruturado em React, empregando Vite e TailwindCSS. A virtualização e o isolamento dos serviços (*sandboxing*) são garantidos pelo uso de contêineres *Docker*.

3.3. Base de Dados

Para a sustentação transacional de cadastros e triagens, adotou-se o banco relacional PostgreSQL, gerenciado por meio do Prisma ORM. Como corpo de conhecimento documental, as Cartilhas de Atenção Pré-Natal do Ministério da Saúde foram vetorizadas e processadas como fonte de verdade (*ground truth*) para os agentes com os documentos listados na Tabela 2.

3.4. Ferramentas de IA

O sistema integra o *Faster-Whisper* para transcrição local e o *ChromaDB* como armazenamento vetorial. A inferência é orquestrada pelo *Ollama*, que executa o modelo *open source* Qwen3.5 (9B, quantização Q4), configurado com hiperparâmetros estritos para mitigar alucinações. O dimensionamento deste modelo, focado em 16.384 *tokens* de contexto, demonstrou o melhor custo-benefício frente às limitações de VRAM (Tabela 3), cujas flutuações dependem diretamente da arquitetura de *hardware* e de otimizações de *drivers* locais [APXML 2024].

Tabela 2. Manuais e cartilhas governamentais utilizadas como base de conhecimento.

Título do Documento	Ano	Referência
Caderneta da Gestante (8ª Ed. Revisada)	2024	[Brasil. Ministério da Saúde 2024]
Guia de Atenção à Saúde da Gestante: Estratificação de Risco	2024	[Minas Gerais. Secretaria de Estado de Saúde 2024]
Manual de Gestão de Alto Risco	2022	[Brasil. Ministério da Saúde 2022]
Guia do Pré-natal do Parceiro para Profissionais de Saúde	2025	[Brasil. Ministério da Saúde 2025]
Ficha Pré-natal: Acolhimento e Identificação	2018	[Brasil. Sistema Único de Saúde 2018]
Atualização em Pré-natal para Profissionais da Atenção Básica	2014	[Santa Catarina. Secretaria de Estado da Saúde 2014]
Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco	2012	[Brasil. Ministério da Saúde 2012a]
Manual Técnico Gestão de Alto Risco (5ª Ed.)	2012	[Brasil. Ministério da Saúde 2012b]
Gestão de Alto Risco: Manual Técnico (5ª Ed.)	2010	[Brasil. Ministério da Saúde 2010]

Tabela 3. Estimativa teórica de consumo de VRAM.

Modelo	Context Size	Parameters	VRAM
GPT-OSS (Q4) 20B	16.384	20B	~17GB
Qwen3.6 (Q4) 35B	16.384	35B	~24GB
Qwen3.5 (Q4) 27B	16.384	27B	~27GB
Qwen3.5 (Q4) 9B	16.384	9B	~10GB
Qwen3 (Q4) 6B	16.384	7B	~5GB

4. Metodologia

A pesquisa adota uma abordagem de Engenharia de Software baseada desenvolvimento ágil de software com sprints no modelo scrum. O desenvolvimento foi dividido em: (i) Modelagem de dados relacionais para prontuários; (ii) Desenvolvimento de um webapp para CRM das gestantes por parte do profissional de saúde; (iii) Implementação de agente "Escriba" para transcrição de consultas e autopreenchimento do prontuário eletrônico do paciente; (iv) Desenvolvimento de motor RAG para consulta de protocolos; (v) Desenvolvimento de um agente de IA para suporte clínico em tempo real;

Quanto a preparação dos dados, o banco de dados vetorial é alimentado através do *Semantic Chunking* das cartilhas governamentais, garantindo que algoritmos de extração vetorial preservassem a semântica das tabelas de exames pré-natais. A governança foi configurada em modo **zero-trust**: os áudios capturados não são armazenados (não persistência), e a transcrição STT cruza o *Model Context Protocol* (MCP) para anonimização de *Entidades Nomeadas* (NER) antes de tocar o orquestrador RAG.

A pesquisa adota uma abordagem de Engenharia de Software baseada desenvolvimento ágil de software com sprints no modelo scrum, contendo:

- Revisão Literária e Modelagem de Dados
- Desenvolvimento do *Backend* e APIs
- Desenvolvimento do *Frontend* (WebApp)
- Agente STT: Transcrição via *Whisper*
- Agente RAG e *Model Context Protocol* (MCP)
- Agente de IA: Assistente Clínico Local

- Anonimizador, *Sandboxing* e *Guardrails*
- Testes de Carga e Validação
- Redação do Artigo Final

A arquitetura docker desenhada reflete o isolamento total dos módulos do sistema, sendo esta estratificada em três subredes *Docker* (*frontend-nw*, *backend-nw* e *data-nw*) para cumprir com o objetivo específico de replicabilidade.




Figura 1. Pipeline arquitetural e ciclo de vida da transação da consulta médica.

Foi planejada a restrição de *Human-in-the-Loop*, sendo assim, todo preenchimento de documentos pela IA é impossibilitado e aguarda validação explícita do profissional de saúde.





Figura 2. Diagrama de implantação e isolamento das redes.

A Figura 3 ilustra o Diagrama de Entidade-Relacionamento (DER) do esquema de banco de dados normalizado, responsável por espelhar os fluxos da Caderneta da Gestante física.



5. Solução Proposta

Os testes modelados englobam validações de segurança (isolação de rotas, vazamento de identificadores de paciente), robustez funcional perante a restrição de campos baseados em limiares biológicos, e análise quantitativa de velocidade de inferência baseada no hardware designado.

Os resultados parciais confirmam a materialização do ecossistema por meio de interfaces focadas na usabilidade clínica.




Figura 4. Painel de gestão (*Dashboard*) da profissional de saúde.

A Figura 5 ilustra o perfil consolidado da gestante, congregando todo o histórico e estratificação de risco.

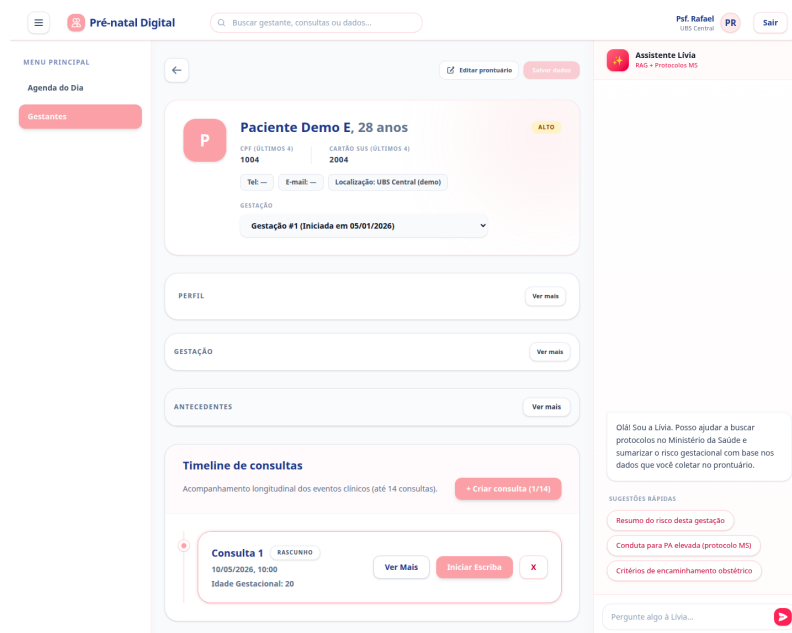


Figura 5. Visão consolidada do prontuário e histórico da gestante.

Por fim, a Figura 6 demonstra a interface de consulta em andamento, onde atua o agente Escriba (para transcrição e apoio à decisão) visando a redução direta da carga cognitiva do profissional.

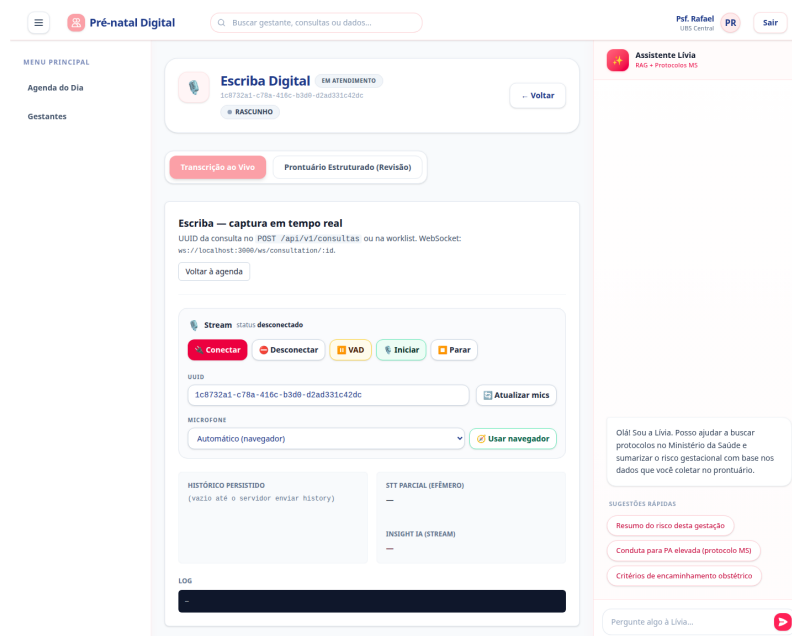


Figura 6. Interface de atendimento em tempo real com suporte do agente Escriba.

6. Implementação, Testes e Resultados Preliminares

A arquitetura do sistema foi desenvolvida assim como planejado utilizando frameworks modernos para a interface web.

O armazenamento utiliza PostgreSQL para gestão de migrações e integridade referencial.

O processamento de linguagem natural está estruturado em uma camada de serviço isolada, permitindo que a IA consuma os dados da consulta sem expor identificadores pessoais (PII), respeitando a LGPD.

O artefato técnico foi disponibilizado em repositório público para fins de reprodutibilidade [Zegrine Duarte 2026].

O plano de testes inicial foca na integridade do fluxo de dados e na precisão das orientações geradas. Foram estipulados os seguintes cenários:

- **Testes Funcionais:** Validação dos esquemas de dados (Zod) para garantir que aferições clínicas (ex: PA, Peso) não aceitem valores fora dos limites biológicos.
- **Testes de Segurança:** Verificação do isolamento de rotas e mascaramento de dados em logs.
- **Testes de Prompt (RAG):** Avaliação qualitativa comparando as sugestões da IA com os protocolos físicos do Ministério da Saúde para identificar possíveis divergências ou alucinações.

7. Resultados

Espera-se um sistema replicável com aumento significativo de interpretabilidade para profissionais de saúde, sem degradação estatisticamente relevante do desempenho em termos de Recall. A auditoria de equidade deverá evidenciar. Espera-se também que a integração de técnicas de explicabilidade (XAI) contribua para maior confiança clínica no uso do sistema como apoio à decisão, reforçando seu potencial de adoção em ambientes reais do SUS.

8. Discussão

A implantação do sistema localmente apresenta fatores limitantes no que se refere aos recursos computacionais em postos de saúde, dada a necessidade de *hardware* avançado (placas de vídeo com alta capacidade de memória VRAM ou Unidades de Processamento de Tensores) para viabilizar latências em tempo real tanto para a conversão áudio-texto quanto para as respostas do modelo generativo.

[GRÁFICO G1: Latência versus Nível de Quantização do Modelo Local]

Observa-se que a quantidade de contexto injetado no prompt através do processo RAG impõe desafios conhecidos como *Lost in the Middle*, impactando diretamente o *F1-Score* quando volumes extensivos de texto técnico são transferidos para o modelo de borda.

[GRÁFICO G2: F1-Score do RAG em relação a diferentes tamanhos de janela de contexto recuperado.]

Finalmente, testes intensivos no módulo de Extração de Entidades Nomeadas (NER) e do protocolo MCP sinalizam que peculiaridades linguísticas (abreviações atípicas e coloquialismos) ainda representam pequenos riscos residuais para identificadores de saúde. Contudo, essa constatação suporta integralmente a necessidade da etapa metodológica adotada de *human-in-the-loop*, que mitiga não apenas potenciais alucinações de conduta, mas valida a confiabilidade final da triagem registrada no banco de dados.

9. Conclusão

A arquitetura especificada no presente manuscrito consolida o design de um ecossistema digital *on-premise* para o atendimento pré-natal no escopo do Sistema Único de Saúde, solucionando a premissa de que a LGPD restringe fluxos dependentes de processamento e extração remota em ambientes de nuvem pública. Por meio da combinação dos métodos *Speech-to-Text* local, *Retrieval-Augmented Generation* restrito às Cartilhas do Ministério da Saúde e do protocolo de anonimização estrito, atende-se ao objetivo de mitigar simultaneamente a elevada carga cognitiva e o risco de vazamento de dados.

A viabilidade técnica comprova-se forte do ponto de vista do ciclo **software** e das blindagens de rede.

Referências

- [Anthropic et al. 2024] Anthropic et al. (2024). Model Context Protocol Specification. <https://modelcontextprotocol.io/>. Especificação aberta orientada ao encadeamento seguro ferramentas–modelo.
- [APXML 2024] APXML (2024). Vram calculator for llms. <https://apxml.com/tools/vram-calculator>. Acessado para dimensionamento de requisitos de hardware.
- [Atheniense and Marques-Neto 2024] Atheniense, A. and Marques-Neto, H. T. (2024). Governança da inteligência artificial no poder judiciário brasileiro: desafios regulatórios e riscos da fragmentação normativa na era digital. *Revista EJEf*, 1(5). Transparência, accountability e governança em IA.
- [Brasil. Ministério da Saúde 2010] Brasil. Ministério da Saúde (2010). *Gestação de Alto Risco: Manual Técnico*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012a] Brasil. Ministério da Saúde (2012a). *Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012b] Brasil. Ministério da Saúde (2012b). *Manual Técnico Gestação de Alto Risco*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2022] Brasil. Ministério da Saúde (2022). *Manual de Gestação de Alto Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2024] Brasil. Ministério da Saúde (2024). *Caderneta da Gestante*. Brasília, DF, 8. ed. rev. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2025] Brasil. Ministério da Saúde (2025). *Guia do Pré-natal do Parceiro para Profissionais de Saúde*. Brasília, DF, 2. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Sistema Único de Saúde 2018] Brasil. Sistema Único de Saúde (2018). *Ficha Pré-natal: Acolhimento e Identificação*. Jaguarão, RS. Acesso em: 5 fev. 2026.
- [Cabitza and colegas 2022] Cabitza, F. and colegas (2022). Responsible ai in healthcare. *arXiv preprint*. arXiv:2203.03616.
- [Dignum 2022] Dignum, V. (2022). Responsible artificial intelligence – from principles to practice. *arXiv preprint*. arXiv:2205.10785.
- [Fergus et al. 2022] Fergus, P., Chalmers, C., Redfern, O., et al. (2022). Using machine learning to predict complications in pregnancy: A systematic review. *Frontiers in Bioengineering and Biotechnology*, 9:780389.
- [Governo Federal do Brasil 2025] Governo Federal do Brasil (2025). Framework de governança de ia para garantir uso ético no estado brasileiro. Agência Gov.
- [Laurenti et al. 2010] Laurenti, R. et al. (2010). Mortes maternas: revisão do fator de correção para os dados oficiais. *Revista Brasileira de Epidemiologia*, 13:1–11.
- [Lekadir and et al. 2022] Lekadir, K. and et al. (2022). Future-ai: guiding principles and consensus recommendations for trustworthy artificial intelligence in medical imaging.

arXiv preprint arXiv:2109.09658. Publicado posteriormente em periódicos de Saúde Digital.

- [Lekadir et al. 2023] Lekadir, K., Feragen, A., Fofanah, A. J., et al. (2023). Future-ai: International consensus guideline for trustworthy and deployable artificial intelligence in healthcare. *arXiv preprint*. arXiv:2309.12325.
- [Minas Gerais. Secretaria de Estado de Saúde 2024] Minas Gerais. Secretaria de Estado de Saúde (2024). *Guia de Atenção à Saúde da Gestante: Critérios para Estratificação de Acompanhamento da Gestante*. Belo Horizonte, MG, 1. ed. edition. Acesso em: 5 fev. 2026.
- [OWASP GenAI Security Project 2023] OWASP GenAI Security Project (2023). OWASP LLM Top 10 for large language model applications. <https://owasp.org/www-project-top-10-for-large-language-model-applications/>. Documento técnico; versão revisada continuamente.
- [Rajpurkar et al. 2022] Rajpurkar, P., Chen, E., Banerjee, O., and Topol, E. J. (2022). Ai in health and medicine. *Nature Medicine*, 28(1):31–38.
- [Roshanzamir and Taghavi 2025] Roshanzamir, F. and Taghavi, M. (2025). Machine learning models to predict risk of maternal morbidity. *JMIR Medical Informatics*, 13.
- [Santa Catarina. Secretaria de Estado da Saúde 2014] Santa Catarina. Secretaria de Estado da Saúde (2014). *Atualização em Pré-natal para Profissionais da Atenção Básica*. Florianópolis, SC, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Shneiderman 2021] Shneiderman, B. (2021). Responsible ai: Bridging from ethics to practice. *Communications of the ACM*, 64(8):32–35.
- [Theme Filha and et al. 2014] Theme Filha, M. M. and et al. (2014). Utilização do sistema de informações sobre nascidos vivos (sinasc) em pesquisas acadêmicas no brasil. *Cadernos de Saúde Pública*, 30:1–21.
- [Tomasi et al. 2018] Tomasi, E., Fernandes, P. A. A., Fischer, T. R., et al. (2018). Acesso à assistência pré-natal no brasil: análise dos dados da pesquisa nacional de saúde 2013. *Revista Brasileira em Promoção da Saúde*, 30(3).
- [Xu et al. 2025] Xu, X., Zhang, Y., Wang, L., et al. (2025). Prediction of high-risk pregnancy based on machine learning: model development and performance evaluation. *Scientific Reports*, 15.
- [Zegrine Duarte 2026] Zegrine Duarte, L. (2026). Sistema de digitalização e inteligência da caderneta de gestante do sus. <https://github.com/LucasZeD/sus-prenatal-ai-icei-puc-minas-cc.git>. Acessado em: 1 abr. 2026.