

Digitalização da Caderneta da Gestante: Um Ecossistema de IA Responsável para Apoio à Decisão Clínica no Pré-Natal

Lucas Zegrine Duarte¹, Humberto Torres Marques Neto¹

¹Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Caixa Postal 1.686 – 30.535-901 – Belo Horizonte – MG – Brazil

{humberto.neto, lucas.duarte}@sga.pucminas.br

Abstract. *Prenatal documentation in Brazil is fragmented between physical and digital records, while the use of Large Language Models in the public sector poses privacy and hallucination risks. This work proposes an on-premise architecture integrating local voice transcription (Faster-Whisper), Retrieval-Augmented Generation over Ministry of Health manuals orchestrated via Ollama, and the Model Context Protocol for sensitive data de-identification. To ensure clinical safety, a mandatory human-in-the-loop validation constraint is applied. The primary contribution is a secure and replicable high-fidelity prototype. The main limitation is the dependence on local hardware with high VRAM capacity to support low-latency inference.*

Resumo. *A documentação de pré-natal no Brasil é fragmentação entre registros físicos e digitais e o uso de Modelos de Linguagem de Grande Escala no setor público levanta riscos de privacidade e alucinação. Este trabalho propõe uma arquitetura on-premise que integra transcrição de voz local (Faster-Whisper), Geração Aumentada por Recuperação sobre manuais do Ministério da Saúde com orquestração via Ollama e o Model Context Protocol para anonimização de dados sensíveis. Para garantir a segurança clínica, aplica-se uma restrição de validação humana obrigatória. A contribuição principal é a materialização de um protótipo de alta fidelidade replicável e seguro. A principal limitação é a dependência de hardware local com alta capacidade de VRAM para suportar inferências com baixa latência.*

Palavras-chave: Cuidado pré-natal; Inteligência artificial; Sistemas de informação em saúde; Privacidade de dados; Geração Aumentada por Recuperação; IA Explicável.

1. Introdução

A Inteligência Artificial (IA) tem demonstrado potencial transformador na saúde pública, oferecendo soluções para otimização de fluxos de trabalho e suporte à decisão [?, ?]. No contexto do atendimento pré-natal, aplicações preditivas baseadas em aprendizado de máquina evidenciam eficácia na identificação precoce de riscos gestacionais [?, ?]. Contudo, a mortalidade e morbidade materna no Brasil permanecem como desafios de saúde pública persistentes, frequentemente agravados por gargalos no acesso e registro adequado de dados durante a assistência [?, ?].

A documentação clínica no *Sistema Único de Saúde* (SUS) enfrenta um cenário de fragmentação, exigindo que o profissional de saúde registre informações simultaneamente

em plataformas digitais pelo e-SUS e em ferramentas físicas, como a Caderneta da Gestante. Essa dualidade impõe maior carga cognitiva durante as consultas, comprometendo o tempo de contato direto e humanizado com a paciente [?, ?].

Para atenuar essa sobrecarga, o presente trabalho propõe a especificação de uma plataforma digital *on-premise* que integra transcrição de voz para texto (*Speech-to-Text*) com agentes de Inteligência Artificial baseados em *Geração Aumentada por Recuperação* (RAG) facilitadores de conhecimento de bases de protocolos de cuidado pré-natal. A ideia principal é automatizar o preenchimento de formulários clínicos durante a consulta, e auxiliar o profissional no cuidado com a paciente utilizando como referências os protocolos oficiais do Ministério da Saúde disponíveis nas cartilhas de estratificação de risco.

Complicações gestacionais e gravidez de alto risco demandam acompanhamento rigoroso. Segundo as diretrizes dos Manuais de Gestação de Alto Risco do Ministério da Saúde [?, ?], condições de risco ou morbidades pré-existentes exigem uma estratificação contínua e o acesso rápido a protocolos de intervenção específicos, fatores que podem sobrecarregar o tempo de atendimento do profissional e geram impactos expressivos na infraestrutura do sistema público [?].

Para otimizar esse monitoramento e atenuar a sobrecarga informacional, modelos generativos têm sido progressivamente propostos como assistentes virtuais clínicos para resumo e triagem de dados [?, ?].

No entanto, a implantação irrestrita de Modelos de Linguagem de Grande Escala (LLMs) em cenários públicos depara-se com duas barreiras críticas: o risco de exposição de dados sensíveis (*Personally Identifiable Information* - PII) [?, ?], violando normativas como a Lei Geral de Proteção de Dados (LGPD), e a propensão à geração de condutas clínicas fabricadas, as alucinações algorítmicas.

Portanto, a justificativa técnica deste projeto fundamenta-se na necessidade de estruturar uma arquitetura que: (i) assegure a governança absoluta dos dados por meio de processamento local e isolado; (ii) minimize o impacto das alucinações utilizando (RAG) para ancorar o agente estritamente em protocolos de referência das cartilhas governamentais; (iii) adote o padrão *Model Context Protocol* (MCP) aliado a estratégias de *human-in-the-loop* para assegurar constante supervisão médica [?, ?]; e (iv) incorpore mecanismos de anonimização e pseudonimização de PII antes de submeter informações sensíveis aos modelos generativos.

A pesquisa baseia-se na seguinte pergunta norteadora: *Como especificar e arquitetar um sistema de apoio ao pré-natal que reduza a carga cognitiva do profissional de saúde, garantindo privacidade local de dados (LGPD) e mitigando alucinações sem eximir a validação médica da tomada de decisão?*

Para responder a este problema geral, três subquestões operacionais são investigadas:

- Como construir uma topologia de rede isolada em contêineres que impossibilite o vazamento de áudio ou dados textuais sensíveis para a internet pública?
- Como mitigar situações em que o profissional confia excessivamente nas sugestões algorítmicas devido à fadiga por meio de um fluxo *human-in-the-loop*?
- Como avaliar a qualidade do modelo e da recuperação de informações na ausência de validação inicial em campo por um Comitê de Ética em Pesquisa?

Este projeto possui como objetivo geral especificar e arquitetar uma plataforma digital *on-premise* para apoio ao pré-natal, integrando *LLMs* fundamentada via *RAG* para reduzir a carga cognitiva do atendimento, com foco em explicabilidade, privacidade e alinhamento às diretrizes da LGPD.

Para atingir o objetivo geral, delineiam-se os seguintes objetivos específicos:

1. Revisar a literatura sobre IA Responsável em saúde pública, focando em explicabilidade, privacidade e governança de dados no contexto do SUS;
2. Formalizar os requisitos técnicos e as histórias de usuário, mapeando a interação entre profissionais de saúde e o sistema para o suporte ao cuidado gestacional;
3. Projetar uma topologia de implantação *on-premise* replicável via contêineres (*Docker*), garantindo a soberania dos dados.
4. Projetar e descrever o fluxo de dados integrando transcrição (*STT*), orquestração via *MCP* e recuperação de conhecimento (*RAG*).
5. Definir mecanismos de mitigação contra alucinações e ameaças de *prompt injection*, estabelecendo protocolos de anonimização e revisão humana obrigatória.

Para viabilizar este escopo, a pesquisa baseia-se na engenharia de software e no desenvolvimento ágil, validando os requisitos por meio de casos clínicos sintéticos. Os resultados obtidos demonstram a efetividade da arquitetura através de um protótipo funcional de alta fidelidade capaz de processar transcrições locais, anonimizar informações e recuperar diretrizes via *RAG* de maneira segura. O restante deste artigo está estruturado da seguinte forma: apresentação do referencial teórico, seguida pelos materiais, metodologia, solução arquitetural proposta, enquanto as Seções subsequentes reúnem a implementação técnica, a análise dos resultados, a discussão dos achados e, por fim, as conclusões.

2. Referencial Teórico

2.1. IA Responsável e Governança em Saúde

A IA Responsável (RAI) transcende a ética teórica ao propor a operacionalização de princípios de transparência e justiça na engenharia de software [?, ?]. Na saúde, essa necessidade é suprida por frameworks como o *FUTURE-AI*, que estabelece diretrizes para a implantação de sistemas confiáveis [?], e o *FAIR-AI*, focado na revisão contínua de modelos clínicos [?].

No cenário brasileiro, a governança deve alinhar-se à Lei Geral de Proteção de Dados (LGPD) e a frameworks institucionais que buscam mitigar riscos regulatórios e fragmentações normativas no setor público [?, ?].

2.2. LLMs e RAG na Saúde Pública

Modelos de Linguagem de Grande Escala (LLMs) oferecem novas possibilidades para a análise de prontuários. Contudo, devido ao risco de alucinações em contextos clínicos, a técnica de *Retrieval-Augmented Generation* (RAG) é empregada para restringir a base de conhecimento do modelo aos Manuais Técnicos de Pré-Natal do Ministério da Saúde.

3. Materiais

Nesta seção, são detalhados os componentes que estruturam o sistema, incluindo os requisitos de *hardware* para execução local, os *frameworks* de desenvolvimento, as bases de dados utilizadas e as ferramentas de Inteligência Artificial implementadas.

3.1. Hardware

Para viabilizar a arquitetura *on-premise*, o hardware foi dimensionado para atender aos requisitos de inferência do *LLM* clínico.

Tabela 1. Especificações de hardware utilizado.

Componente	Especificação
CPU	Intel Core i7-14700K
GPU	Nvidia RTX 5060ti 16gb
RAM	Vengeance 2x 16GB DDR5 6000MHz
PSU	750W Gold Corsair
Motherboard	Asus Rog Strox z790 Rog Maximus Hero

O poder computacional mínimo depende primariamente da quantidade de VRAM dedicada para alocar simultaneamente o motor RAG e os modelos de agente *LLM* clínico.

3.2. Software e Frameworks

O ambiente adota *TypeScript* como linguagem principal. O *backend* foi desenvolvido em *Node.js* utilizando o micro-framework Hono para orquestração assíncrona da API. O *frontend* foi estruturado em React, empregando Vite e TailwindCSS. A virtualização e o isolamento dos serviços (*sandboxing*) são garantidos pelo uso de contêineres *Docker*.

3.3. Base de Dados

Para a sustentação transacional de cadastros e triagens, adotou-se o banco relacional PostgreSQL, gerenciado por meio do Prisma ORM. Como corpo de conhecimento documental, as Cartilhas de Atenção Pré-Natal do Ministério da Saúde foram vetorizadas e processadas como fonte de verdade (*ground truth*) para os agentes com os documentos listados na Tabela ??.

Tabela 2. Manuais e cartilhas governamentais utilizadas como base de conhecimento.

Título do Documento	Ano	Referência
Caderneta da Gestante	2024	[?]
Guia de Atenção à Saúde: Estratificação de Risco	2024	[?]
Manual de Gestação de Alto Risco	2022	[?]
Guia do Pré-natal do Parceiro para Profissionais de Saúde	2025	[?]
Ficha Pré-natal: Acolhimento e Identificação	2018	[?]
Atualização em Pré-natal para Profissionais da Atenção Básica	2014	[?]
Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco	2012	[?]
Manual Técnico Gestação de Alto Risco (5ª Ed.)	2012	[?]
Gestação de Alto Risco: Manual Técnico (5ª Ed.)	2010	[?]

3.4. Ferramentas de IA

O sistema integra o *Faster-Whisper* para transcrição local e o *ChromaDB* como armazenamento vetorial. O dimensionamento deste modelo, focado em 16.384 *tokens* de contexto, demonstrou o melhor custo-benefício frente às limitações de VRAM (Tabela ??), cujas

Tabela 3. Estimativa teórica de consumo de VRAM.

Modelo	Context Size	Parameters	VRAM
GPT-OSS (Q4) 20B	16.384	20B	~17GB
Qwen3.6 (Q4) 35B	16.384	35B	~24GB
Qwen3.5 (Q4) 27B	16.384	27B	~27GB
Qwen3.5 (Q4) 9B	16.384	9B	~10GB
Qwen3 (Q4) 6B	16.384	7B	~5GB

flutuações dependem diretamente da arquitetura de *hardware* e de otimizações de *drivers* locais [?].

A inferência é orquestrada pelo *Ollama*, que executa o modelo *open source* Qwen3.5 (9B, quantização Q4), configurado com hiperparâmetros estritos para mitigar alucinações. As configurações de inferência e as métricas de particionamento semântico (*chunking*) para a base vetorial estão padronizadas conforme o detalhamento da Tabela ??.

Tabela 4. Hiperparâmetros de inferência (Ollama) e particionamento (RAG).

Hiperparâmetros do LLM (Qwen3.5)		Parâmetros do RAG e Chunking	
Parâmetro	Valor	Parâmetro	Valor
num_ctx	65.536	embedding_model	nommic-embed-text
num_batch	256	chunk_max_chars	900
num_predict	8.192	chunk_overlap	80
temperature	0.1	max_chunks_retrieved	6
top_p	0.9	rerank_enabled	True
top_k	40	rerank_pool_size	48
repeat_penalty	1.08	mmr_lambda	0.62

4. Metodologia

A pesquisa adota uma abordagem de Engenharia de Software baseada desenvolvimento ágil de software com desenvolvimento dividido em: (i) Modelagem de dados relacionais para prontuários; (ii) Desenvolvimento de um webapp para CRM das gestantes por parte do profissional de saúde; (iii) Implementação de agente "Escriba" para transcrição de consultas e autopreenchimento do prontuário eletrônico do paciente; (iv) Desenvolvimento de motor RAG para consulta de protocolos; (v) Desenvolvimento de um agente de IA para suporte clínico em tempo real;

Quanto a preparação dos dados, o banco de dados vetorial é alimentado através do *Semantic Chunking* das cartilhas governamentais, garantindo que algoritmos de extração vetorial preservassem a semântica das tabelas de exames pré-natais. A governança foi configurada em modo *zero-trust* os áudios capturados não são armazenados (não persistência), e a transcrição STT cruza o *MCP* para anonimização de *Entidades Nomeadas* (NER) antes de tocar o orquestrador RAG.

A pesquisa adota uma abordagem de Engenharia de Software baseada desenvolvimento ágil de software com sprints no modelo scrum, contendo:

- Revisão Literária e Modelagem de Dados
- Desenvolvimento do *Backend* e APIs

- Desenvolvimento do *Frontend* (WebApp)
- Agente STT: Transcrição via *Whisper*
- Agente RAG e *Model Context Protocol* (MCP)
- Agente de IA: Assistente Clínico Local
- Anonimizador, *Sandboxing* e *Guardrails*
- Testes de Carga e Validação
- Redação do Artigo Final

A arquitetura docker desenhada reflete o isolamento total dos modulos do sistema, sendo esta estratificada em três subredes *Docker* (*frontend-nw*, *backend-nw* e *data-nw*) para cumprir com o objetivo específico de replicabilidade.




Figura 1. Pipeline arquitetural e ciclo de vida da transação da consulta médica.

Foi planejada a restrição de *Human-in-the-Loop*, sendo assim, todo preenchimento de documentos pela IA é impossibilitado e aguarda validação explícita do profissional de saúde.




Figura 2. Diagrama de implantação e isolamento das redes.

A Figura ?? ilustra o Diagrama de Entidade-Relacionamento (DER) do esquema de banco de dados normalizado, responsável por espelhar os fluxos da Caderneta da Gestante física com toda a lógica da cartilha disponibilizada pelo Ministério da Saúde[?].

5. Solução Proposta

A materialização do ecossistema foi guiada por requisitos funcionais (RF) e histórias de usuário (US) estritos, formalizados para mitigar os riscos inerentes à aplicação clínica de Inteligência Artificial. Dentre os requisitos notáveis que moldaram a proposição da arquitetura, destacam-se:

- **Agente Escriba e Transitoriedade (RF03/RF04):** Exigência de transcrição de voz local em tempo real para preenchimento estruturado de formulários, operando sob a premissa estrita de *não persistir* o áudio bruto ou as transcrições literais nos bancos de dados transacionais.
- **Apoio à Decisão via RAG (RF05):** Implementação de um assistente interativo ancorado de forma exclusiva nos Manuais Técnicos do Ministério da Saúde, bloqueando o fornecimento de condutas baseadas apenas no conhecimento paramétrico generalista do modelo.
- **Validação Obrigatória (Human-in-the-Loop - US04):** Restrição sistêmica que impede a consolidação autônoma de qualquer inferência da IA no prontuário definitivo, transferindo a responsabilidade da "aprovação" ou "rejeição" das sugestões obrigatoriamente para o profissional de saúde.
- **Intervenção Manual Corretiva (US07):** Garantia estrutural de que todos os formulários pré-preenchidos pelos agentes generativos sejam plenamente editáveis durante a consulta, prevenindo a persistência de falsos positivos sistêmicos.
- **Mascaramento de PII (US13):** Interceptação e anonimização de dados de identificação pessoal por meio de um intermediador de privacidade no MCP, garantindo conformidade com a LGPD antes de submeter os contextos à inferência semântica.
- **Alertas Sistêmicos de Alto Risco (US05):** Geração automática de sinalizações visuais críticas caso os parâmetros vitais ou laboratoriais extraídos pela IA ultrapassem os limiares de segurança definidos nas cartilhas governamentais.
- **Portabilidade Documental (US06):** Capacidade de exportação dinâmica de todos os registros clínicos em um arquivo PDF espelhado visualmente à ficha oficial de acompanhamento do SUS, assegurando a continuidade do cuidado analógico.
- **Integração Preventiva da Paciente (US10/US11):** Disparo assíncrono de resumos do plano de cuidado e alertas de agendamento via canais de mensageria, visando combater ativamente os índices de evasão nas consultas de acompanhamento.

A partir do cumprimento destas restrições arquiteturais e diretrizes de projeto, os resultados práticos desta etapa de desenvolvimento culminaram na construção de um protótipo funcional de alta fidelidade.

Este artefato tangibiliza o ecossistema proposto ao projetar o fluxo do *Backend* em interfaces sob a ótica da experiência do usuário e usabilidade, visando a redução da curva de aprendizado dos profissionais de saúde do SUS.

A Figura ?? exibe o painel de gestão (*Dashboard*), projetado para prover uma visão rápida da agenda e das pacientes em acompanhamento.




Figura 4. Painel de gestão (*Dashboard*) da profissional de saúde.

A Figura ?? ilustra o perfil consolidado da gestante, congregando todo o histórico

e estratificação de risco.




Figura 5. Visão consolidada do prontuário e histórico da gestante.

Por fim, a Figura ?? demonstra a interface de consulta em andamento, onde atua o agente Escriba (para transcrição e apoio à decisão) visando a redução direta da carga cognitiva do profissional.




Figura 6. Interface de atendimento em tempo real com suporte do agente Escriba.

Todo o código-fonte do ecossistema e suas respectivas configurações de *deploy* foram disponibilizados em repositório público visando garantir a transparência e a reprodutibilidade do artefato construído [?].

6. Testes

7. Resultados

8. Discussão

9. Conclusão

Referências

- [Anthropic et al. 2024] Anthropic et al. (2024). Model Context Protocol Specification. <https://modelcontextprotocol.io/>. Especificação aberta orientada ao encadeamento seguro ferramentas–modelo.
- [APXML 2024] APXML (2024). Vram calculator for llms. <https://apxml.com/tools/vram-calculator>. Acessado para dimensionamento de requisitos de hardware.
- [Atheniense and Marques-Neto 2024] Atheniense, A. and Marques-Neto, H. T. (2024). Governança da inteligência artificial no poder judiciário brasileiro: desafios regulatórios e riscos da fragmentação normativa na era digital. *Revista EJE*, 1(5). Transparência, accountability e governança em IA.
- [Brasil. Ministério da Saúde 2010] Brasil. Ministério da Saúde (2010). *Gestação de Alto Risco: Manual Técnico*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012a] Brasil. Ministério da Saúde (2012a). *Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012b] Brasil. Ministério da Saúde (2012b). *Manual Técnico Gestação de Alto Risco*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2022] Brasil. Ministério da Saúde (2022). *Manual de Gestação de Alto Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2024] Brasil. Ministério da Saúde (2024). *Caderneta da Gestante*. Brasília, DF, 8. ed. rev. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2025] Brasil. Ministério da Saúde (2025). *Guia do Pré-natal do Parceiro para Profissionais de Saúde*. Brasília, DF, 2. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Sistema Único de Saúde 2018] Brasil. Sistema Único de Saúde (2018). *Ficha Pré-natal: Acolhimento e Identificação*. Jaguarão, RS. Acesso em: 5 fev. 2026.
- [Cabitza and colegas 2022] Cabitza, F. and colegas (2022). Responsible ai in healthcare. *arXiv preprint*. arXiv:2203.03616.
- [Clusmann et al. 2023] Clusmann, J., Kolbinger, F. R., Muti, H. S., Carrero, Z. I., Eckardt, J.-N., Laleh, N. G., Löffler, C. M. L., Muti, S. C., Quirke, P., Truhn, D., et al. (2023). The future landscape of large language models in medicine. *Communications Medicine*, 3(1):141.
- [Dignum 2022] Dignum, V. (2022). Responsible artificial intelligence – from principles to practice. *arXiv preprint*. arXiv:2205.10785.
- [Fergus et al. 2022] Fergus, P., Chalmers, C., Redfern, O., et al. (2022). Using machine learning to predict complications in pregnancy: A systematic review. *Frontiers in Bioengineering and Biotechnology*, 9:780389.
- [Governo Federal do Brasil 2025] Governo Federal do Brasil (2025). Framework de governança de ia para garantir uso ético no estado brasileiro. Agência Gov.

- [Laurenti et al. 2010] Laurenti, R. et al. (2010). Mortes maternas: revisão do fator de correção para os dados oficiais. *Revista Brasileira de Epidemiologia*, 13:1–11.
- [Lekadir and et al. 2022] Lekadir, K. and et al. (2022). Future-ai: guiding principles and consensus recommendations for trustworthy artificial intelligence in medical imaging. *arXiv preprint arXiv:2109.09658*. Publicado posteriormente em periódicos de Saúde Digital.
- [Lekadir et al. 2023] Lekadir, K., Feragen, A., Fofanah, A. J., et al. (2023). Future-ai: International consensus guideline for trustworthy and deployable artificial intelligence in healthcare. *arXiv preprint. arXiv:2309.12325*.
- [Minas Gerais. Secretaria de Estado de Saúde 2024] Minas Gerais. Secretaria de Estado de Saúde (2024). *Guia de Atenção à Saúde da Gestante: Critérios para Estratificação de Acompanhamento da Gestante*. Belo Horizonte, MG, 1. ed. edition. Acesso em: 5 fev. 2026.
- [OWASP GenAI Security Project 2023] OWASP GenAI Security Project (2023). OWASP LLM Top 10 for large language model applications. <https://owasp.org/www-project-top-10-for-large-language-model-applications/>. Documento técnico; versão revisada continuamente.
- [Rajpurkar et al. 2022] Rajpurkar, P., Chen, E., Banerjee, O., and Topol, E. J. (2022). Ai in health and medicine. *Nature Medicine*, 28(1):31–38.
- [Roshanzamir and Taghavi 2025] Roshanzamir, F. and Taghavi, M. (2025). Machine learning models to predict risk of maternal morbidity. *JMIR Medical Informatics*, 13.
- [Santa Catarina. Secretaria de Estado da Saúde 2014] Santa Catarina. Secretaria de Estado da Saúde (2014). *Atualização em Pré-natal para Profissionais da Atenção Básica*. Florianópolis, SC, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Shneiderman 2021] Shneiderman, B. (2021). Responsible ai: Bridging from ethics to practice. *Communications of the ACM*, 64(8):32–35.
- [Theme Filha and et al. 2014] Theme Filha, M. M. and et al. (2014). Utilização do sistema de informações sobre nascidos vivos (sinasc) em pesquisas acadêmicas no brasil. *Cadernos de Saúde Pública*, 30:1–21.
- [Tomasi et al. 2018] Tomasi, E., Fernandes, P. A. A., Fischer, T. R., et al. (2018). Acesso à assistência pré-natal no brasil: análise dos dados da pesquisa nacional de saúde 2013. *Revista Brasileira em Promoção da Saúde*, 30(3).
- [Xu et al. 2025] Xu, X., Zhang, Y., Wang, L., et al. (2025). Prediction of high-risk pregnancy based on machine learning: model development and performance evaluation. *Scientific Reports*, 15.
- [Zegrine Duarte 2026] Zegrine Duarte, L. (2026). Sistema de digitalização e inteligência da caderneta de gestante do sus. <https://github.com/LucasZeD/sus-prenatal-ai-icei-puc-minas-cc.git>. Acessado em: 1 abr. 2026.