

Digitalização da Caderneta da Gestante: Uma Arquitetura de IA Responsável para Apoio à Decisão Clínica no Pré-Natal

Lucas Zegrine Duarte¹, Humberto Torres Marques Neto¹

¹Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Caixa Postal 1.686, 30.535-901, Belo Horizonte, MG, Brazil

{humberto.neto, lucas.duarte}@sga.pucminas.br

Abstract. Prenatal documentation in Brazil is fragmented between physical and digital records, while the use of Large Language Models in the public sector poses privacy and hallucination risks. This work proposes an on-premise architecture integrating local voice transcription (Faster-Whisper), Retrieval-Augmented Generation over Ministry of Health manuals orchestrated via Ollama, and a dedicated privacy gateway to mask PII before model inference. To ensure clinical safety, a mandatory human-in-the-loop validation constraint is applied. The primary contribution is a secure and replicable high-fidelity prototype. The main limitation is the dependence on local hardware with high VRAM capacity to support low-latency inference.

Resumo. A documentação de pré-natal no Brasil é fragmentada entre registros físicos e digitais, e o uso de Modelos de Linguagem de Grande Escala no setor público levanta riscos de privacidade e alucinação. Este trabalho propõe uma arquitetura on-premise que integra transcrição de voz local (Faster-Whisper), Geração Aumentada por Recuperação sobre manuais do Ministério da Saúde com orquestração via Ollama e um gateway de privacidade dedicado para mascarar PII antes da inferência do modelo. Para garantir a segurança clínica, exige-se revisão médica antes de salvar qualquer registro (human-in-the-loop). A contribuição principal é a implementação de um protótipo de alta fidelidade replicável com foco em privacidade, auditabilidade e revisão humana. A principal limitação é a dependência de hardware local com alta capacidade de VRAM para suportar inferências com baixa latência.

Palavras-chave: Cuidado pré-natal; Inteligência artificial; Sistemas de informação em saúde; Privacidade de dados; Geração Aumentada por Recuperação; IA Explicável.

1. Introdução

A Inteligência Artificial (IA) tem demonstrado potencial transformador na saúde pública, oferecendo soluções para otimização de fluxos de trabalho e suporte à decisão [Rajpurkar et al. 2022, Cabitza et al. 2022]. No contexto do atendimento pré-natal, aplicações preditivas baseadas em aprendizado de máquina apontam potencial e desempenho promissor em bases experimentais na identificação precoce de riscos gestacionais [Pi et al. 2025, Bertini et al. 2022]. Contudo, a mortalidade e morbidade materna no Brasil permanecem como desafios de saúde pública persistentes, frequentemente

agravados por gargalos no acesso e registro adequado de dados durante a assistência [Nunes et al. 2017, Laurenti et al. 2010].

A documentação clínica no *Sistema Único de Saúde* (SUS) enfrenta um cenário de fragmentação, exigindo que o profissional de saúde registre informações simultaneamente em plataformas digitais pelo e-SUS e em ferramentas físicas, como a Cader-neta da Gestante. Essa dualidade pode ampliar esforço de registro durante as consul-tas, podendo comprometer o tempo de contato direto e humanizado com a paciente [Viellas et al. 2014, Rajpurkar et al. 2022].

Para atenuar essa sobrecarga, o presente trabalho propõe a especificação de uma plataforma digital *on-premise* que integra transcrição de voz para texto (*Speech-to-Text*) e agentes de IA baseados em *Geração Aumentada por Recuperação* (RAG). A plataforma busca automatizar o preenchimento de formulários clínicos durante a consulta e apoiar o profissional, com base em protocolos oficiais do Ministério da Saúde, no cuidado com a paciente.

Complicações gestacionais e gravidez de alto risco demandam acompanhamento rigoroso. Segundo as diretrizes dos Manuais de Gestação de Alto Risco do Ministério da Saúde [Brasil. Ministério da Saúde 2022, Brasil. Ministério da Saúde 2012b], condições de risco ou morbidades pré-existentes exigem uma estratificação contínua e o acesso rápido a protocolos de intervenção específicos, fatores que podem sobrecarregar o tempo de atendimento do profissional e geram impactos expressivos na infraestrutura do sistema público [Vasudevan et al. 2025].

Para otimizar esse monitoramento e atenuar a sobrecarga informacional, modelos generativos têm sido progressivamente propostos como assistentes virtuais clínicos para resumo e triagem de dados [Clusmann et al. 2023, Rajpurkar et al. 2022].

No entanto, a implantação irrestrita de Modelos de Linguagem de Grande Escala (LLMs) em cenários públicos depara-se com duas barreiras críticas: o risco de exposição de dados sensíveis (*Personally Identifiable Information* - PII) [OWASP GenAI Security Project 2025], violando normativas como a Lei Geral de Proteção de Dados (LGPD), e a propensão à geração de condutas clínicas fabricadas, as alucinações algorítmicas.

Portanto, a justificativa técnica deste projeto fundamenta-se na estruturação de uma arquitetura local e auditável para apoio documental ao pré-natal, reduzindo a dependência de serviços externos no processamento de áudio e texto sensível. A proposta combina execução *on-premise*, recuperação aumentada por documentos oficiais do Ministério da Saúde e revisão humana obrigatória, de modo que o modelo generativo não receba autonomia decisória nem persista informações sem validação profissional.

A adoção de RAG busca reduzir o risco de respostas desvinculadas dos protocolos utilizados como base documental, embora não elimine a necessidade de avaliação de aderência e de revisão humana. De forma complementar, o gateway de privacidade aplica mecanismos de detecção e mascaramento de PII antes da inferência pelo modelo gene-rativo, contribuindo para um fluxo mais controlável sob a perspectiva de privacidade por desenho, minimização de dados e auditabilidade. Assim, o foco do trabalho não é de-monstrar eficácia assistencial, mas avaliar a viabilidade técnica, os limites e os trade-offs de uma arquitetura assistiva, local e não autônoma para o contexto do SUS.

A pesquisa baseia-se na seguinte pergunta norteadora: *Como especificar, implementar e avaliar um protótipo 'on-premise' para apoio documental ao pré-natal a partir de protocolos públicos, sem atribuir autonomia decisória ao modelo generativo?*

Para responder a este problema geral, as seguintes subquestões operacionais são investigadas:

- Como estruturar uma arquitetura local em contêineres que reduza o risco de exposição de áudio ou dados textuais sensíveis?
- Qual é o desempenho do módulo RAG na recuperação de documentos e trechos relevantes dos manuais oficiais de pré-natal?
- Qual é a aderência das respostas geradas por um LLM local aos critérios de protocolo de atendimento pré-natal no SUS?
- Em que medida um anonimizador de dados pessoais sensíveis mascara entidades antes da inferência pelo modelo generativo?
- Quais são os custos de latência associados à execução local do protótipo em comparação com uma linha de base externa?

Este projeto possui como objetivo geral especificar, implementar e avaliar uma plataforma digital *on-premise* para apoio documental ao pré-natal, integrando *LLMs* fundamentadas via *RAG*, mascaramento de PII para apoiar o registro e a tomada de decisão clínica, com ênfase em explicabilidade, privacidade por desenho, auditabilidade e alinhamento às diretrizes públicas de saúde.

Para atingir o objetivo geral, delineiam-se os seguintes objetivos específicos:

1. Revisar a literatura sobre IA Responsável em saúde pública para fundamentar as decisões arquiteturais e delimitar a lacuna tecnológica no contexto do SUS;
2. Dimensionar os requisitos de hardware e projetar uma topologia de rede *on-premise* isolada em contêineres *Docker*;
3. Desenvolver um protótipo funcional voltado à consulta assistida de informações de pré-natal, mantendo revisão humana obrigatória;
4. Implementar um módulo de anonimização dedicado ao mascaramento e sanitização de PII brasileiras;
5. Estruturar a recuperação de conhecimento via (*RAG*) com base em documentos públicos oficiais;
6. Avaliar o desempenho do protótipo por meio de métricas de recuperação, aderência automática de respostas em testes sintéticos e análise de latência.
7. Analisar os ganhos e perdas entre privacidade local, custo computacional, latência e viabilidade de implantação em ambientes de produção.

O restante deste artigo está estruturado da seguinte forma: o referencial teórico embasa as decisões de design; os materiais e a metodologia detalham o ambiente e o fluxo de desenvolvimento; a solução proposta apresenta a arquitetura e interfaces criadas; e as seções finais discutem o desempenho e as limitações do ecossistema.

2. Referencial Teórico

Esta seção define os conceitos centrais do trabalho e indica como cada um responde a riscos do uso de *LLMs* no pré-natal do SUS.

2.1. IA Responsável e Governança Clínica

Com base em princípios de IA responsável e design centrado no humano [Shneiderman 2021, Cabitza et al. 2022], este trabalho adota mecanismos de transparência, responsabilização e supervisão humana como requisitos de projeto. No contexto proposto, esses princípios são operacionalizados por meio de uma arquitetura local (*on-premise*), interfaces de revisão obrigatória das saídas do modelo e restrição explícita de autonomia decisória da IA.

2.2. Retrieval-Augmented Generation (RAG)

Modelos de Linguagem de Grande Escala baseados apenas em conhecimento paramétrico apresentam limitações para acessar, atualizar e prover proveniência sobre informações factuais. A técnica de *Retrieval-Augmented Generation* (RAG) combina geração textual com recuperação de evidências externas em tempo de inferência, condicionando a resposta ao contexto documental recuperado [Lewis et al. 2020]. Revisões recentes também apontam que a qualidade da recuperação, a fidelidade ao contexto e a robustez contra ruído permanecem desafios centrais em sistemas RAG [Sharma 2025]. Aplicando essa premissa à arquitetura, o modelo foi ancorado exclusivamente em cartilhas e manuais oficiais do Ministério da Saúde, empregando particionamento (*chunking*) semântico e hiperparâmetros conservadores para priorizar aderência documental em detrimento da fluidez generativa.

2.3. Restrição Human-in-the-Loop

No tocante à supervisão, a literatura de IA responsável centrada no humano defende que sistemas automatizados em domínios críticos devem preservar a agência humana e manter mecanismos claros de responsabilização [Shneiderman 2021]. Em consonância com essa diretriz, a plataforma adota estritamente a restrição *human-in-the-loop*, na qual nenhuma predição, sugestão ou extração da Inteligência Artificial é salva de forma autônoma. O sistema atua como ferramenta assistiva e documental, exigindo que o médico ou enfermeiro valide ou edite os dados antes de sua persistência no prontuário eletrônico.

2.4. Segurança em LLMs e Mascaramento de Dados

A integração de LLMs em fluxos clínicos expande a superfície de ataques, demandando proteções contra injeção de *prompt* e exposição de dados sensíveis, conforme mapeado pelo *OWASP Top 10 for Large Language Model Applications* [OWASP GenAI Security Project 2025]. Para endereçar essas vulnerabilidades regulatórias e técnicas, o ecossistema proposto incorpora um *gateway* de privacidade customizado, munido de Expressões Regulares (Regex) e Reconhecimento de Entidades Nomeadas (NER) operando localmente. Esse mecanismo atua higienizando identificadores de saúde brasileiros, como CPF e CNS, antes do trânsito de dados para o modelo, reduzindo o risco de vazamento de informações pessoalmente identificáveis (PII).

3. Materiais

Nesta seção, são detalhados os componentes que estruturam o sistema, incluindo os requisitos de *hardware* para execução local, os *frameworks* de desenvolvimento, as bases de dados utilizadas e as ferramentas de Inteligência Artificial implementadas.

3.1. Hardware

A escolha do modelo obedeceu ao critério de viabilidade operacional local, sendo o protótipo executado em ambiente com CPU Intel i7-14700K, 32GB de RAM e GPU Nvidia RTX 5060 Ti com 16GB de VRAM. Embora o model card do Qwen3.5 9B indique suporte a contexto padrão de 262.144 tokens, adotou-se uma janela operacional reduzida de 16.384 tokens no protótipo, em função das restrições locais de VRAM, latência e estabilidade de inferência [Qwen Team 2026]. A escolha do Qwen3.5 9B quantizado em Q4 decorreu da compatibilidade com a VRAM disponível, evitando *offloading* para RAM/CPU e aumento expressivo do tempo até o primeiro token (TTFT).

3.2. Software e Frameworks

O ambiente adota *TypeScript* como linguagem principal. O *backend* foi desenvolvido em *Node.js* utilizando o micro-*framework* Hono e o *frontend* foi estruturado em React, empregando Vite e TailwindCSS. A execução em contêineres *Docker* contribui para segmentação lógica e isolamento operacional, reduzindo a exposição de PII em caso de comprometimento.

Para transcrição, integra-se o *Faster-Whisper* com processamento local e descarte imediato do stream de áudio, evitando o envio a terceiros e reduzindo a superfície de vazamento.

A orquestração do LLM clínico ocorre via *Ollama*; para apoio à decisão, empregam-se hiperparâmetros conservadores (Tabela 4) para reduzir a variabilidade, favorecendo a aderência ao contexto recuperado.

3.3. Base de Dados

A camada transacional (cadastros e triagens) utiliza *PostgreSQL*, gerenciado via *Prisma ORM*. Como base documental, as Cartilhas de Atenção Pré-Natal do Ministério da Saúde foram vetorizadas como fonte de verdade (*ground truth*) (Tabela 1). O acervo inclui edições de 2010–2025; para mitigar conflitos no RAG, adotou-se re-ranqueamento por *Maximal Marginal Relevance* (MMR) [Carbonell and Goldstein 1998], priorizando relevância e diversidade de *chunks* sem redundância.

Tabela 1. Base de conhecimento documental: Manuais e cartilhas.

Título do Documento	Ano	Referência
Guia do Pré-natal do Parceiro [...]	2025	[Brasil. Ministério da Saúde 2025]
Caderneta da Gestante	2024	[Brasil. Ministério da Saúde 2024]
Guia de Atenção à Saúde	2024	[SES-MG 2024]
Manual de Gestação de Alto Risco	2022	[Brasil. Ministério da Saúde 2022]
Ficha Pré-natal	2018	[Brasil. Sistema Único de Saúde 2018]
Atualização em Pré-natal [...]	2014	[SES-SC 2014]
Cadernos de Atenção Básica	2012	[Brasil. Ministério da Saúde 2012a]
Manual Técnico Gestação de Alto Risco	2012	[Brasil. Ministério da Saúde 2012b]
Gestação de Alto Risco	2010	[Brasil. Ministério da Saúde 2010]

3.4. Ferramentas de IA

A seleção do modelo obedeceu a um critério de viabilidade operacional *on-premise*, com 16GB de VRAM dedicados e janela de contexto configurada em 16.384 *tokens* para RAG.

Modelos cujo consumo estimado de VRAM superasse 13GB após quantização Q4 foram descartados para evitar *offloading* de memória, reconhecendo-se que essas estimativas são teóricas e dependem da arquitetura de hardware, *drivers*, mecanismo de inferência e parâmetros de execução [APXML 2024].

Tabela 2. Estimativa teórica de consumo de VRAM.

Modelo	Contexto	Parâmetros	VRAM
Qwen3.6 (Q4)	16.384	35B	~24 GB
Qwen3.5 (Q4)	16.384	27B	~27.4 GB
GPT-OSS (Q4)	16.384	20B	~17.3 GB
Qwen3 (Q4)	16.384	14B	~16.12 GB
Qwen3.5 (Q4)	16.384	9B	~10.51 GB
Qwen3 (Q4)	16.384	8B	~10.41 GB

* Cálculo de VRAM teórico estimado baseado em <https://apxml.com/tools/vram-calculator>.

Para a escolha entre os candidatos compatíveis com 16GB de VRAM, consultou-se o comparativo público não revisado por pares LLMBase [LLMBase 2026], que agrega scores de benchmarks (GPQA, HLE, índices compostos, etc.) para avaliação dos modelos Qwen3 14B e Qwen3.5 9B.

Embora esses resultados reflitam inferência em infraestrutura de larga escala de API e não reproduzam a arquitetura local escolhida, indicam que o Qwen3.5 9B supera o Qwen3 14B em GPQA (80,6% vs 60,4%) e no índice composto de inteligência (32,4 vs 16,2), o que corrobora a preferência pelo menor modelo que surpreendeu apresentando melhor desempenho em raciocínio nos benchmarks agregados consultados.

Tabela 3. Comparação de modelos Qwen3 14B e Qwen3.5 9B.

Métrica	Qwen3 14B (Reasoning)	Qwen3.5 9B (Reasoning)
Inteligência	16.2	32.4
GPQA	60.4%	80.6%
HLE	4.3%	13.3%
Data de Lançamento	Abr. 2025	Mar. 2026

* Dados de benchmark extraídos de <https://llmbase.ai/compare/qwen3-14b-instruct-reasoning,qwen3-5-9b/>.

A inferência é orquestrada pelo *Ollama* com o modelo Qwen3.5 (9B, quantização Q4) da Alibaba, parametrizado para mitigar alucinações (Tabela 4) na arquitetura de hardware disponível. A estruturação da base de conhecimento inclui o particionamento semântico (*chunking*) das diretrizes e sua vetorização única, com persistência no armazenamento vetorial. Para gerenciar possíveis sobreposições ou conflitos temporais entre manuais de anos distintos, incorporou-se a técnica de *Maximal Marginal Relevance* (MMR) como mecanismo de re-ranqueamento (*reranking*). O MMR foi utilizado para descartar redundâncias, filtrando os documentos para reter um subconjunto de contextos que maximiza tanto a relevância em relação à consulta quanto a diversidade informacional apresentada ao modelo.

Tabela 4. Hiperparâmetros de inferência (Ollama) e RAG.

LLM (Qwen3.5)		RAG & Chunking	
num_ctx	16.384	embedding_model	nomic-embed-text
num_batch	256	chunk_max_chars	900
temperature	0.1	max_chunks	6
top_p	0.9	rerank_enabled	True

4. Metodologia

A pesquisa adota a Engenharia de Software com desenvolvimento ágil (Scrum) para construção do artefato, organizada em cinco frentes integradas: (i) modelagem relacional do prontuário; (ii) *webapp* de gestão e consulta de pacientes; (iii) agente Escriba para transcrição e extração estruturada; (iv) motor RAG ancorado nas cartilhas do Ministério da Saúde; e (v) assistente clínico local de apoio à decisão.

A arquitetura reflete o isolamento dos módulos em três subredes *Docker* (*frontend-nw*, *backend-nw* e *data-nw*), conforme a *stack* detalhada na Seção 3 (Materiais).

A sanitização de PII e a adoção do modo *zero-trust* seguem o módulo de privacidade descrito anteriormente, fundamentando-se nos requisitos de minimização da LGPD apresentados na Seção 2. Todo o áudio capturado é processado localmente e descartado ao final da interação.

A Figura 1 sintetiza o ciclo de vida da transação da consulta médica, estruturado nas seguintes etapas operacionais:

- **Captura e transcrição local (STT):** o fluxo de áudio é transcrito em tempo de execução via *Whisper* com diarização.
- **Sanitização de entrada:** o *gateway* remove ou mascara as *PII* na transcrição antes de compor a consulta ao módulo RAG.
- **Recuperação (Retriever):** a busca retorna os trechos relevantes e aplica re-ranqueamento por *Maximal Marginal Relevance* (MMR) para mitigar redundâncias e conflitos temporais entre edições dos manuais.
- **Geração (Generator):** o LLM sintetiza a resposta clínica com hiperparâmetros conservadores, privilegiando a aderência ao contexto recuperado.
- **Apresentação e validação humana:** a interface exibe as sugestões de preenchimento, mantendo a edição manual integralmente disponível.

Para cumprir a restrição de segurança clínica, adota-se o *Human-in-the-Loop*, onde nenhum dado sugerido pela IA é gravado no banco de dados sem a confirmação explícita do profissional (US04), garantindo o controle total sobre o registro. A principal ameaça à validade interna é a geração de conteúdo não suportado por protocolo (alucinação), mitigada por RAG restrito a diretrizes oficiais e *Human-in-the-Loop*.

A ameaça de exposição de *PII* é mitigada por processamento local em um *gateway* de mascaramento aplicado antes da recuperação e inferência. O anonimizador foi implementado em arquitetura híbrida, combinando regras




Figura 1. Pipeline arquitetural e ciclo de vida da transação da consulta médica.

determinísticas de Expressões Regulares (Regex) para identificadores brasileiros e um módulo de Reconhecimento de Entidades Nomeadas (NER) especializado em português biomédico. Como modelo de NER, utilizou-se OpenMed/OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1, disponibilizado no Hugging Face [Science 2026].

A modelagem relacional foi derivada da 8ª edição revisada da Caderneta da Gestante, contemplando entidades para paciente, gestação, consultas, sinais vitais, exames, antecedentes, prontuário e registros de atendimento. O DER completo foi disponibilizado como material suplementar no repositório do projeto.

5. Solução Proposta


A arquitetura derivou de requisitos funcionais (RF) e histórias de usuário (US) mapeados a riscos clínicos, operacionais e regulatórios. A Tabela 5 resume essa relação, demonstrando como as ferramentas teóricas abordadas foram convertidas em funcionalidades práticas no protótipo. Esses controles foram implementados em um protótipo de alta fidelidade (Figura 2), cobrindo a agenda de atendimentos, o prontuário consolidado da paciente e a tela de consulta ativa com o agente Escriba e o assistente clínico.

6. Avaliação Experimental e Resultados


A avaliação experimental foi conduzida em três frentes complementares: recuperação documental, geração de respostas e segurança do fluxo clínico. O objetivo foi verificar se

Tabela 5. Requisitos, riscos mitigados e mecanismos de controle.


RF/US	Risco	Decisão de design	Mitigação esperada
RF03/04 RF05	Retenção indevida de áudio. Alucinação em conduta clínica.	STT local; áudio não persistido RAG restrito a manuais	Reduz superfície de vazamento. Respostas embasadas em protocolo oficial
US04	Automação indevida e não responsabilização	Bloqueio de persistência sem aprovação	Decisão final do profissional
US13	Exposição de PII ao modelo	Gateway de anonimização	Dados em trânsito anonimizados
US05	Atraso na identificação de alto risco	Alertas por limiares das cartilhas	Sinalização visual imediata na consulta
US06	Descontinuidade do registro físico	Exportação PDF	Continuidade do cuidado manual



(a) Painel de gestão (Dashboard).



(b) Visão consolidada do prontuário.



(c) Interface de atendimento em tempo real.

Figura 2. Interfaces do protótipo de alta fidelidade: gestão, histórico e atendimento.

a arquitetura proposta, baseada em RAG, LLM local e *gateway* de privacidade, consegue recuperar evidências dos manuais oficiais, produzir respostas aderentes aos protocolos e impedir vazamento de informações sensíveis antes da inferência. O conjunto de testes utilizado contém 100 perguntas em português, das quais 90 avaliam aderência a protocolos e 10 são perguntas distratoras (*trap*). A distribuição por dificuldade foi de 42 itens fáceis, 35 médios e 23 difíceis. Quatro itens classificados como `human_judge` foram mantidos para revisão qualitativa e não compõem o denominador da métrica automática de APR. Este sistema de avaliação foi estruturado em conformidade com práticas da indústria para avaliação de agentes de IA, como a do *Microsoft Copilot Studio Evaluation Framework* [Microsoft 2026].

6.1. Recuperação Semântica

O módulo de recuperação foi avaliado isoladamente com $top-k=6$ e expansão de consulta ativada. Foram utilizadas três métricas: *Hit@6*, que verifica se o documento-fonte esperado aparece entre os seis primeiros *chunks*; *Mean Reciprocal Rank* (MRR), que pondera a posição do primeiro documento correto; e *phrase_recall*, que mede a presença das frases esperadas nos trechos recuperados. A Tabela 6 apresenta os resultados por dificuldade.

Tabela 6. Desempenho do módulo RAG por nível de dificuldade ($n = 100$).

Dificuldade	n	Hit@6 (%)	MRR Médio
Easy	42	76,2%	0,4837
Medium	35	68,6%	0,3633
Hard	23	95,7%	0,6536
Global	100	78,0%	0,4807

O *phrase_recall* médio global foi de 47,1%. O melhor desempenho em itens difíceis não deve ser interpretado como maior facilidade clínica, mas como efeito provável da especificidade lexical de consultas sobre alto risco, que tendem a produzir assinaturas vetoriais mais discriminativas. Em contraste, perguntas de rotina pré-natal competem com trechos semanticamente próximos de diferentes manuais, reduzindo a precisão do ranqueamento.

6.2. Geração de Resposta

A geração foi avaliada por meio da Taxa de Aprovação de Respostas (APR), calculada sobre itens elegíveis à avaliação automática, e da Taxa de Falha em Perguntas Distratoras (TFR), calculada sobre os itens *trap*. O modelo local Qwen3.5 9B foi executado com e sem RAG para medir o ganho incremental da recuperação. O Gemini-3.1-Flash-Lite foi utilizado apenas como linha de base externa de comparação, sem integrar a arquitetura proposta nem alterar sua premissa local.

Tabela 7. Desempenho dos modelos na geração de respostas.

Provedor	Modo RAG	APR (%)	TFR (%)
Qwen3.5 9B (Ollama)	Off	53,1% (51/96)	20,0% (2/10)
Qwen3.5 9B (Ollama)	On	57,3% (55/96)	10,0% (1/10)
Gemini-3.1-Flash-Lite	On	61,5% (59/96)	0,0% (0/10)

A ativação do RAG no modelo local elevou a APR de 53,1% para 57,3% e reduziu a TFR (Taxa de Erro de Conduta) de 20,0% para 10,0%. O ganho é limitado, indicando que a recuperação documental contribui para reduzir respostas inseguras, mas não garante aderência clínica estrita quando o modelo precisa negar condutas, reproduzir termos literais ou resolver conflitos entre documentos. No conjunto total de execuções, foram registradas 3 falhas em itens *trap* e 120 reprovações de protocolo nas 258 avaliações automáticas de frases obrigatórias. Os quatro itens excluídos da avaliação demandam revisão qualitativa da equipe clínica e não entram no denominador da Tabela 7.

6.3. Privacidade, escopo e latência

O módulo de anonimização foi submetido a 50 frases sintéticas, totalizando 76 entidades sensíveis avaliadas, incluindo CPF, Cartão Nacional de Saúde (CNS), e-mail, telefone, nomes completos e cadeias numéricas longas. Não houve vazamento detectado no conjunto testado, conforme a Tabela 8. Esse resultado valida a implementação inicial do mascaramento, mas não elimina a necessidade de testes com variações linguísticas, abreviações e ruído de transcrição.

Tabela 8. Taxa de vazamento de PII por tipo de entidade.

Entidade	n	Leak Rate (%)
CNS	11	0,0%
CPF	12	0,0%
E-mail	12	0,0%
Nome Completo	21	0,0%
Cadeias Numéricas Longas	8	0,0%
Telefone	12	0,0%
Total Global	76	0,0%

Além das métricas agregadas, aplicou-se o roteiro funcional (GT01-GT05), composto por cinco casos sintéticos para validar comportamentos essenciais do protótipo. Os casos GT01, GT02 e GT03 avaliam respostas clínicas com RAG e LLM em cenários de risco alto extraídos dos manuais protocolares. O GT04 avalia sanitização direta de PII. O GT05 avalia a capacidade de recusar uma requisição fora do escopo de pré-natal.

O roteiro funcional obteve sucesso em quatro dos cinco casos avaliados. Os três casos clínicos com RAG e LLM foram aprovados, assim como o caso de sanitização direta de PII. A falha ocorreu no GT05, no qual a barreira de escopo não conteve adequadamente uma requisição fora do domínio pré-natal. Esse resultado indica que a segurança comportamental não deve depender apenas de *system prompts* e o módulo de privacidade

deve incorporar verificações determinísticas ou classificadores de escopo antes da síntese pelo modelo.

Quanto à eficiência computacional, as métricas foram segregadas por configuração para evitar que a linha de base em nuvem distorça a interpretação operacional do protótipo local. A Tabela 9 apresenta os resultados médios.

Tabela 9. Latência média por configuração de execução.

Configuração	Retrieve (ms)	Latência total (s)	TTFT (ms)	tokens/s
Qwen3.5 9B (Ollama)	–	11,71	470,1	32,5
Qwen3.5 9B (Ollama) + RAG on	373,1	15,59	2789,7	32,4
Gemini-3.1-Flash-Lite + RAG on	372,7	4,55	3501,9	360,6

Para o protótipo local, a recuperação vetorial acrescentou aproximadamente 373 ms ao fluxo, enquanto a latência total do Qwen3.5 9B com RAG foi de 15590,1 ms. Portanto, o gargalo operacional permanece na inferência local do LLM e no aumento de contexto provocado pelo RAG, não na busca vetorial. A linha de base externa apresentou maior vazão de geração, mas não representa a premissa de privacidade local da arquitetura proposta. Esse resultado reforça que a adoção em produção de baixo custo ainda é limitada pelos requisitos de hardware, especialmente VRAM, tempo de inferência e estabilidade sob carga.

7. Discussão

Os resultados indicam viabilidade técnica parcial da arquitetura proposta. A combinação de execução local, RAG restrito a documentos oficiais e mascaramento de PII atende ao objetivo de reduzir dependência de nuvem pública e de oferecer um fluxo mais controlável do ponto de vista da LGPD. Os resultados mostram que o protótipo ainda não pode ser interpretado como sistema autônomo de apoio clínico, o protótipo foi concebido como ferramenta assistiva e documental. A APR do modelo local com RAG foi de 57,3%, e a TFR permaneceu em 10,0%; portanto, a recuperação documental melhora o comportamento do LLM, mas não elimina erros em respostas que exigem negação explícita, fidelidade literal ou distinção entre protocolos semanticamente próximos.

O desempenho do RAG ajuda a explicar esse limite, onde o *Hit@6* global de 78,0% demonstre boa capacidade de recuperar ao menos um documento relevante entre os seis primeiros trechos, o *phrase_recall* médio de 47,1% indica que a evidência recuperada nem sempre contém as frases necessárias para satisfazer o critério de resposta. Ou seja, o modelo tende a receber um documento correto, mas sem o trecho suficientemente específico para responder com segurança. Esse comportamento é compatível com a assimetria observada por dificuldade: itens difíceis, frequentemente associados a termos técnicos de alto risco, foram mais bem recuperados do que itens médios, nos quais há maior competição lexical entre manuais de pré-natal de rotina.

A comparação com o Gemini cria uma nova perspectiva quanto a falha da solução local. O modelo externo atingiu APR superior e TFR nula sob a mesma configuração de RAG, sugerindo que o recuperador atual pode sustentar respostas melhores quando

acoplado a modelos mais capazes. O resultado aponta, portanto, para a necessidade de avaliar modelos locais maiores ou melhor adaptados a terminologia clínica, desde que acompanhados de hardware compatível e controles de privacidade equivalentes.

O resultado de 0,0% de vazamento de PII no corpus sintético é positivo, mas sua validade externa é limitada. Nomes brasileiros compostos, abreviações, fala espontânea, erros de transcrição e regionalismos podem gerar padrões fora da distribuição testada. Como o módulo STT não foi avaliado sistematicamente, a transcrição é tratada como dado sensível em trânsito e como pré-preenchimento editável. Essa limitação reforça o papel do fluxo *human-in-the-loop*: o profissional deve validar tanto a informação clínica quanto a integridade dos dados inseridos antes da persistência.

As limitações do estudo decorrem do próprio escopo experimental. A avaliação realizada mede viabilidade arquitetural, privacidade, recuperação documental, aderência automática e comportamento funcional em casos sintéticos; ela não mede eficácia assistencial. Não houve avaliação com gestantes, profissionais de saúde ou dados clínicos reais, logo, os resultados não permitem inferir redução efetiva de carga cognitiva, usabilidade em consulta ou impacto sobre desfechos de cuidado. Essa limitação é compatível com a pergunta de pesquisa adotada, que prioriza viabilidade técnica e segurança arquitetural, mas impede conclusões sobre adoção clínica real.

Como trabalhos futuros, recomenda-se refinar a indexação por metadados de versão dos manuais, implementar barreiras determinísticas de escopo antes da geração, avaliar o sistema em áudio clínico simulado, submeter o protótipo a estudos com profissionais de saúde mediante aprovação ética, aplicar revisão clínica independente aos itens ambíguos, comparar modelos locais maiores e mais recentes, e mensurar custo computacional, consumo de VRAM, latência e estabilidade sob carga. O cenário atual de hardware ainda limita a aplicação de LLMs locais em produção de baixo custo, especialmente quando há necessidade de baixa latência e modelos com maior número de parâmetros. Espera-se, contudo, que a evolução de modelos, técnicas de quantização, aceleração em hardware e métodos de RAG torne esse tipo de sistema progressivamente mais simples de implantar em ambientes assistenciais.

Por fim, a principal contribuição do protótipo é explicitar uma arquitetura replicável na qual privacidade, auditabilidade e revisão humana são requisitos de projeto. O estudo também fornece um benchmark inicial para avaliar recuperação, geração, privacidade e escopo em pré-natal, criando uma base para comparações futuras com modelos e configurações mais robustas.

8. Conclusão

Este trabalho especificou, implementou e avaliou um sistema protótipo *on-premise* para apoio documental ao pré-natal no contexto do SUS, integrando transcrição local, RAG sobre manuais oficiais, LLM executado via Ollama com revisão humana obrigatória e um *gateway* de anonimização de dados.

A pergunta norteadora foi respondida de forma parcial: a arquitetura mostrou-se tecnicamente viável como base assistiva, auditável e não autônoma, mas os resultados de geração, escopo e latência indicam que o sistema ainda não possui robustez suficiente para uso clínico sem supervisão profissional. A topologia em contêineres deve ser en-

tendida como decisão de privacidade por desenho, não como comprovação de isolamento absoluto, pois não foram realizados testes específicos de segurança de rede.

Na avaliação experimental, o módulo *RAG* alcançou *Hit@6* global de 78,0% e MRR médio de 0,4807, mas o *phrase_recall* médio de 47,1%, indicando capacidade razoável de recuperar documentos relevantes, embora o *phrase_recall* mostre que a evidência recuperada nem sempre contém o trecho necessário para satisfazer integralmente o critério de resposta. O módulo de privacidade não apresentou vazamento no conjunto sintético de 76 entidades avaliadas, embora esse resultado não substitua testes com fala espontânea, abreviações, erros de transcrição e maior variação linguística. A latência média de 15,59 segundos no fluxo local com *RAG* evidencia que a inferência local e os requisitos de hardware ainda limitam a adoção de baixo custo em produção. Por fim, a revisão humana obrigatória foi validada como restrição de projeto, pois os resultados reforçam que o sistema deve permanecer assistivo, auditável e não autônomo. A aprovação de quatro dos cinco casos funcionais do roteiro (GT01-GT05) indica coerência funcional inicial, enquanto a falha no GT05 evidencia a necessidade de barreiras de escopo antes da geração via *LLM*.

Como contribuição, o estudo entrega uma arquitetura replicável, um fluxo de privacidade coerente com os princípios da LGPD e um benchmark inicial reproduzível para avaliação técnica de recuperação, geração, mascaramento de PII, escopo e latência em documentos de pré-natal e evidências quantitativas sobre os trade-offs entre execução local e custo computacional. A continuidade do projeto deve priorizar curadoria do índice vetorial, avaliação sistemática do STT, testes com modelos maiores e mais recentes, análise de consumo de VRAM e validação futura com profissionais de saúde em termos de eficácia assistencial e usabilidade em consulta mediante aprovação ética. No cenário atual, os requisitos de hardware ainda limitam a adoção de baixo custo em produção; contudo, avanços em modelos, quantização, aceleração em hardware e técnicas de *RAG* podem tornar esse tipo de sistema progressivamente mais viável em ambientes reais.

9. Declarações Finais

Os materiais suplementares estão disponíveis no repositório público do projeto: <https://github.com/lucaszegrine/sus-prenatal-ai-icei-puc-minas-cc>.

O estudo não envolve participantes humanos, não utiliza dados clínicos reais identificáveis e não foi submetido ao Comitê de Ética em Pesquisa da PUC Minas.

Durante a preparação do texto, foi utilizado o modelo Gemini 3.1 Pro (Google, 04/2026) para revisão gramatical e refinamento de clareza, sem geração de resultados experimentais, análise de resultados ou compartilhamento de dados sensíveis onde todo o conteúdo obtido de forma automatizada foi revisado e editado conforme necessário sob total responsabilidade do autor.

Referências

- [APXML 2024] APXML (2024). Vram calculator for llms. <https://apxml.com/tools/vram-calculator>. Acesso em: 20 abr. 2026.
- [Bertini et al. 2022] Bertini, A., Salas, R., Chabert, S., Sobrevia, L., and Pardo, F. (2022). Using machine learning to predict complications in pregnancy: A systematic review. *Frontiers in Bioengineering and Biotechnology*, 9:780389.
- [Brasil. Ministério da Saúde 2010] Brasil. Ministério da Saúde (2010). *Gestação de Alto Risco: Manual Técnico*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012a] Brasil. Ministério da Saúde (2012a). *Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012b] Brasil. Ministério da Saúde (2012b). *Manual Técnico Gestação de Alto Risco*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2022] Brasil. Ministério da Saúde (2022). *Manual de Gestação de Alto Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2024] Brasil. Ministério da Saúde (2024). *Caderneta da Gestante*. Brasília, DF, 8. ed. rev. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2025] Brasil. Ministério da Saúde (2025). *Guia do Pré-natal do Parceiro para Profissionais de Saúde*. Brasília, DF, 2. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Sistema Único de Saúde 2018] Brasil. Sistema Único de Saúde (2018). *Ficha Pré-natal: Acolhimento e Identificação*. Jaguarão, RS. Acesso em: 5 fev. 2026.
- [Cabitza et al. 2022] Cabitza, F., Ciucci, D., Pasi, G., and Viviani, M. (2022). Responsible AI in healthcare. *arXiv preprint*. arXiv:2203.03616v1.
- [Carbonell and Goldstein 1998] Carbonell, J. G. and Goldstein, J. (1998). The use of mmr, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 335–336.
- [Clusmann et al. 2023] Clusmann, J., Kolbinger, F. R., Muti, H. S., Carrero, Z. I., Eckardt, J.-N., Laleh, N. G., Löffler, C. M. L., Muti, S. C., Quirke, P., Truhn, D., et al. (2023). The future landscape of large language models in medicine. *Communications Medicine*, 3(1):141.
- [Laurenti et al. 2010] Laurenti, R. et al. (2010). Mortes maternas: revisão do fator de correção para os dados oficiais. *Revista Brasileira de Epidemiologia*, 13:1–11.
- [Lewis et al. 2020] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- [LLMBase 2026] LLMBase (2026). Llm benchmark comparator. <https://llmbase.ai/compare/qwen3-14b-instruct-reasoning,qwen3-5-9b/>. Acesso em: 20 abr. 2026.

- [Microsoft 2026] Microsoft (2026). Criar e executar avaliações de agentes no Microsoft Copilot Studio. <https://learn.microsoft.com/pt-br/microsoft-copilot-studio/analytics-agent-evaluation-create>. Acesso em: 25 mar. 2026.
- [Nunes et al. 2017] Nunes, A. D. d. S., Amador, A. E., Dantas, A. P. d. Q. M., Azevedo, U. N. d., and Barbosa, I. R. (2017). Acesso à assistência pré-natal no brasil: análise dos dados da pesquisa nacional de saúde. *Revista Brasileira em Promoção da Saúde*, 30(3).
- [OWASP GenAI Security Project 2025] OWASP GenAI Security Project (2025). OWASP Top 10 for large language model applications. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>. Versão 2025 (v2.0); CC BY-SA 4.0. Acesso em: 20 abr. 2026.
- [Pi et al. 2025] Pi, X., Wang, J., Chu, L., Zhang, G., and Zhang, W. (2025). Prediction of high-risk pregnancy based on machine learning algorithms. *Scientific Reports*, 15:15561.
- [Qwen Team 2026] Qwen Team (2026). Qwen3.5-9B model card. <https://huggingface.co/Qwen/Qwen3.5-9B>. Acesso em: 20 abr. 2026.
- [Rajpurkar et al. 2022] Rajpurkar, P., Chen, E., Banerjee, O., and Topol, E. J. (2022). Ai in health and medicine. *Nature Medicine*, 28(1):31–38.
- [Science 2026] Science, O. (2026). Openmed-pii-portuguese-snowflakemed-large-568m-v1: Portuguese pii detection model.
- [SES-MG 2024] SES-MG (2024). *Guia de Atenção à Saúde da Gestante: Critérios para Estratificação de Acompanhamento da Gestante*. Belo Horizonte, MG, 1. ed. edition. Acesso em: 5 fev. 2026.
- [SES-SC 2014] SES-SC (2014). *Atualização em Pré-natal para Profissionais da Atenção Básica*. Florianópolis, SC, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Sharma 2025] Sharma, C. (2025). Retrieval-augmented generation: A comprehensive survey of architectures, enhancements, and robustness frontiers. *arXiv preprint arXiv:2506.00054*. Preprint.
- [Shneiderman 2021] Shneiderman, B. (2021). Responsible ai: Bridging from ethics to practice. *Communications of the ACM*, 64(8):32–35.
- [Vasudevan et al. 2025] Vasudevan, L., Kibria, M. G., Kucirka, L. M., Shieh, K., Wei, M., Masoumi, S., Balasubramanian, S., Victor, A., Conklin, J. L., Gurcan, M. N., Stuebe, A. M., and Page, D. (2025). Machine learning models to predict risk of maternal morbidity and mortality from electronic medical record data: Scoping review. *Journal of Medical Internet Research*, 27:e68225.
- [Viellas et al. 2014] Viellas, E. F., Domingues, R. M. S. M., Dias, M. A. B., Gama, S. G. N. d., Theme Filha, M. M., Costa, J. V. d., Bastos, M. H., and Leal, M. d. C. (2014). Assistência pré-natal no brasil. *Cadernos de Saúde Pública*, 30(Suppl. 1):S85–S100.