

Caderneta Inteligente da Gestante: utilizando IA generativa com uma abordagem responsável para apoio ao pré-natal

Lucas Zegrine Duarte¹, Humberto Torres Marques Neto¹

¹Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Caixa Postal 1.686, 30.535-901, Belo Horizonte, MG, Brazil

{humberto.neto, lucas.duarte.1327493}@sga.pucminas.br

Abstract. *Prenatal documentation in Brazil is fragmented between physical and digital records, while the use of Large Language Models in the public sector poses privacy and hallucination risks. This work proposes an on-premise architecture integrating local voice transcription, Retrieval-Augmented Generation over Ministry of Health manuals orchestrated via Ollama, and a dedicated privacy gateway to mask PII before model inference. Clinical safety is addressed through mandatory human-in-the-loop validation. The main contribution is a replicable high-fidelity prototype focused on privacy, auditability, and human review. The main limitation is the dependence on local hardware with high VRAM capacity to support low-latency inference.*

Resumo. *A documentação de pré-natal no Brasil é fragmentada entre registros físicos e digitais, enquanto o uso de LLMs no setor público levanta riscos de privacidade e alucinação. Este trabalho propõe uma arquitetura on-premise que integra transcrição de voz local, Geração Aumentada por Recuperação sobre manuais do Ministério da Saúde orquestrada via Ollama e um gateway de privacidade para mascarar PII antes da inferência do modelo. A segurança clínica é tratada por meio de validação humana obrigatória. A principal contribuição é um protótipo de alta fidelidade replicável com foco em privacidade, auditabilidade e revisão humana. A principal limitação é a dependência de hardware local com alta capacidade de VRAM para inferência com baixa latência.*

Palavras-chave: Cuidado pré-natal; Inteligência artificial; Sistemas de informação em saúde; Privacidade de dados; Geração Aumentada por Recuperação; IA Explicável; Aplicações de LLM em saúde.

1. Introdução

A Inteligência Artificial (IA) tem demonstrado potencial transformador na saúde pública, oferecendo soluções para otimização de fluxos de trabalho e suporte à decisão [Rajpurkar et al. 2022, Cabitza et al. 2022]. No contexto do atendimento pré-natal, estudos com bases reais de imagem e avaliação fetal têm explorado análises clínicas específicas, como a avaliação de expressões faciais associadas à dor fetal [Bernardes et al. 2022], reforçando o interesse em soluções digitais aplicadas ao acompanhamento pré-natal. Contudo, a mortalidade e a morbidade materna no Brasil permanecem como desafios persistentes de saúde pública, associados a desigualdades no acesso

à assistência pré-natal e à necessidade de correção dos dados oficiais sobre mortes maternas [Nunes et al. 2017, Laurenti et al. 2010].

A documentação clínica no *Sistema Único de Saúde* (SUS) combina registros em sistemas digitais e instrumentos físicos independentes, como fichas de pré-natal e a Caderneta da Gestante [Brasil. Sistema Único de Saúde 2018, Brasil. Ministério da Saúde 2024]. Essa fragmentação dificulta a integração entre sistemas médicos [Cifuentes et al. 2015]. Na prática clínica, a dispersão das informações também aumenta o esforço de documentação dos profissionais de saúde, especialmente em contextos que exigem monitoramento contínuo, identificação de sinais de risco e consulta frequente a protocolos assistenciais.

Essa demanda torna-se particularmente relevante no pré-natal de alto risco. Segundo as diretrizes dos Manuais de Gestação de Alto Risco do Ministério da Saúde [Brasil. Ministério da Saúde 2022, Brasil. Ministério da Saúde 2012b], condições de risco ou morbidades pré-existentes exigem estratificação contínua e acesso rápido a protocolos de acompanhamento. Diante do volume de informações envolvido nesse processo, modelos generativos têm sido propostos como assistentes virtuais clínicos para resumo e triagem de dados [Clusmann et al. 2023, Rajpurkar et al. 2022].

No entanto, a implantação irrestrita de Modelos de Linguagem de Grande Escala (LLMs) em cenários públicos de saúde enfrenta barreiras críticas, incluindo o risco de exposição de dados sensíveis (*Personally Identifiable Information* – PII), com potenciais implicações para a conformidade com a Lei Geral de Proteção de Dados (LGPD) [OWASP GenAI Security Project 2025, Brasil 2018]. Além disso, estudos apontam limitações no uso autônomo desses modelos em decisões clínicas, incluindo falhas em seguir instruções e sensibilidade ao contexto fornecido [Hager et al. 2024], bem como risco de geração de respostas não fundamentadas ou clinicamente inadequadas [Asgari et al. 2025].

Diante dessas limitações, este trabalho propõe a especificação, implementação e avaliação de uma plataforma digital *on-premise* para apoio documental ao pré-natal, com foco no registro clínico durante a própria consulta, sem substituir a validação profissional. A abordagem proposta combina transcrição de voz para texto (*Speech-to-Text*), recuperação aumentada (RAG) por documentos oficiais do Ministério da Saúde e secretarias estaduais de saúde, mascaramento de PII, e validação profissional obrigatória. O trabalho também avalia em que medida modelos menores, executados localmente, podem alcançar desempenho próximo ao de modelos fechados de maior porte nessa tarefa, dentro de limites computacionais razoáveis para uso cotidiano. Essa comparação é relevante porque pode reduzir a dependência de serviços externos no processamento de áudio e dados textuais sensíveis.

Embora a adoção de RAG busque aproximar as respostas dos protocolos utilizados como base documental, ela não elimina a necessidade de avaliar a aderência das saídas geradas. Da mesma forma, o mascaramento de PII antes da inferência reduz a exposição de dados sensíveis, mas não substitui mecanismos de validação e controle ao longo do fluxo. Por isso, a arquitetura proposta é concebida como um sistema assistivo e não autônomo, no qual o modelo generativo não recebe autonomia decisória nem persiste informações sem validação profissional. A partir dessa delimitação, este trabalho baseia-

se na seguinte pergunta norteadora: *Como especificar, implementar e avaliar um protótipo on-premise para apoio documental ao pré-natal a partir de protocolos públicos, sem atribuir autonomia decisória ao modelo generativo?* Essa pergunta norteadora desdobra-se nas seguintes questões de pesquisa, identificadas como RQ1–RQ5 ao longo do artigo:

- **RQ1:** Como estruturar uma arquitetura local em contêineres que reduza o risco de exposição de áudio ou dados textuais sensíveis?
- **RQ2:** Qual é o desempenho do módulo RAG na recuperação de documentos e trechos relevantes dos manuais oficiais de pré-natal?
- **RQ3:** Qual é a aderência das respostas geradas por um LLM local aos protocolos de atendimento pré-natal no SUS?
- **RQ4:** Em que medida um anonimizador de dados pessoais sensíveis mascara entidades antes da inferência pelo modelo generativo?
- **RQ5:** Quais são os custos de latência associados à execução local em comparação com uma linha de base externa?

O objetivo geral deste trabalho é especificar, implementar e avaliar uma plataforma digital *on-premise* para apoio documental ao pré-natal, integrando um *LLM* fundamentado por RAG e mecanismos de mascaramento de PII, com ênfase em explicabilidade, privacidade por desenho, auditabilidade e alinhamento às diretrizes públicas de saúde. Para atingir esse objetivo, delineiam-se os seguintes objetivos específicos:

1. Desenvolver um protótipo funcional voltado à consulta assistida de informações de pré-natal, mantendo revisão humana obrigatória;
2. Implementar um módulo de anonimização dedicado ao mascaramento e sanitização de PII brasileiras;
3. Estruturar a recuperação de conhecimento com base em documentos públicos oficiais;
4. Avaliar o desempenho do protótipo por meio de métricas de recuperação, aderência automática de respostas em testes sintéticos e análise de latência.
5. Analisar os ganhos e perdas entre privacidade local, custo computacional, latência e viabilidade de implantação em ambientes de produção.

O artigo está organizado da seguinte forma: a Seção 2 apresenta os fundamentos teóricos que orientam a proposta; as Seções 3 e 4 descrevem os materiais, o ambiente experimental, a arquitetura e as interfaces da plataforma; e a Seção 6 apresenta os experimentos conduzidos para responder às perguntas de pesquisa. Por fim, a Seção 7 discute os resultados obtidos, e a Seção 8 sintetiza as conclusões do estudo.

2. Referencial Teórico

Esta seção define os conceitos centrais do trabalho e indica como cada um responde a riscos do uso de LLMs no pré-natal do SUS.

2.1. IA Responsável e Governança Clínica

Com base em princípios de IA responsável e design centrado no humano [Shneiderman 2021, Cabitza et al. 2022], este trabalho adota mecanismos de transparência, responsabilização e supervisão humana como requisitos de projeto. No contexto proposto, esses princípios são operacionalizados por meio de uma arquitetura local (*on-premise*), interfaces de revisão obrigatória das saídas do modelo e restrição explícita de autonomia decisória da IA.

2.2. Retrieval-Augmented Generation (RAG)

Modelos de Linguagem de Grande Escala baseados apenas em conhecimento paramétrico apresentam limitações para acessar, atualizar e prover proveniência sobre informações factuais. A técnica de *Retrieval-Augmented Generation* (RAG) combina geração textual com recuperação de evidências externas em tempo de inferência, condicionando a resposta ao contexto documental recuperado [Lewis et al. 2020]. Revisões recentes também apontam que a qualidade da recuperação, a fidelidade ao contexto e a robustez contra ruído permanecem desafios centrais em sistemas RAG [Sharma 2025]. Aplicando essa premissa à arquitetura, o modelo foi ancorado em cartilhas e manuais oficiais do Ministério da Saúde, empregando particionamento (*chunking*) semântico e hiperparâmetros conservadores para priorizar aderência documental em detrimento da fluidez generativa.

2.3. Restrição Human-in-the-Loop

No tocante à supervisão, a literatura de IA responsável centrada no humano defende que sistemas automatizados em domínios críticos devem preservar a agência humana e manter mecanismos claros de responsabilização [Shneiderman 2021]. Em consonância com essa diretriz, a plataforma adota estritamente a restrição *human-in-the-loop*, na qual nenhuma predição, sugestão ou extração da Inteligência Artificial é salva de forma autônoma. O sistema atua como ferramenta assistiva e documental, exigindo que o médico ou enfermeiro valide ou edite os dados antes de sua persistência no prontuário eletrônico.

2.4. Segurança em LLMs e Mascaramento de Dados

A integração de LLMs em fluxos clínicos expande a superfície de ataques, demandando proteções contra injeção de *prompt* e exposição de dados sensíveis, conforme mapeado pelo *OWASP Top 10 for Large Language Model Applications* [OWASP GenAI Security Project 2025]. Para endereçar essas vulnerabilidades regulatórias e técnicas, o ecossistema proposto incorpora um *gateway* de privacidade customizado, munido de Expressões Regulares (Regex) e Reconhecimento de Entidades Nomeadas (NER) operando localmente. Esse mecanismo atua higienizando identificadores de saúde brasileiros, como CPF e CNS, antes do trânsito de dados para o modelo, reduzindo o risco de vazamento de informações pessoalmente identificáveis (PII).

3. Materiais

Nesta seção, são detalhados os componentes que estruturam o sistema, incluindo os requisitos de *hardware* para execução local, os *frameworks* de desenvolvimento, as bases de dados utilizadas e as ferramentas de Inteligência Artificial implementadas.

A escolha do modelo obedeceu ao critério de viabilidade operacional local, sendo o protótipo executado em ambiente com CPU Intel i7-14700K, 32GB de RAM e GPU Nvidia RTX 5060 Ti com 16GB de VRAM. Embora o model card do Qwen3.5 9B indique suporte a contexto padrão de 262.144 tokens, adotou-se uma janela operacional reduzida de 16.384 tokens no protótipo, em função das restrições locais de VRAM, latência e estabilidade de inferência [Qwen Team 2026]. A escolha do Qwen3.5 9B quantizado em Q4 decorreu da compatibilidade com a VRAM disponível, evitando *offloading* para RAM/CPU e aumento expressivo do tempo até o primeiro token (TTFT).

O ambiente adota *TypeScript* como linguagem principal. O *backend* foi desenvolvido em *Node.js* utilizando o micro-*framework* Hono e o *frontend* foi estruturado

em React, empregando Vite e TailwindCSS. A execução em contêineres *Docker* contribui para segmentação lógica e isolamento operacional, reduzindo a exposição de PII em caso de comprometimento. Para transcrição, integra-se o *Faster-Whisper* com processamento local e descarte imediato do stream de áudio, evitando o envio a terceiros e reduzindo a superfície de vazamento. A diarização é realizada localmente pelo pipeline *pyannote/speaker-diarization-3.1*, responsável por segmentar o áudio em turnos associados a rótulos anônimos de locutor.

A orquestração do LLM clínico ocorre via *Ollama* utilizando temperatura de 0,1, definida como escolha operacional para reduzir a variabilidade e privilegiar fidelidade ao contexto recuperado em RAG [Sharma 2025].

Tabela 1. Hiperparâmetros de inferência (Ollama) e RAG.

LLM (Qwen3.5)		RAG & Chunking	
num_ctx	16.384	embedding_model	nomic-embed-text
num_batch	256	chunk_max_chars	900
temperature	0.1	max_chunks	6
top_p	0.9	rerank_enabled	True

3.1. Base de Dados

A camada transacional (cadastros e triagens) utiliza *PostgreSQL*, gerenciado via *Prisma ORM*. As Cartilhas de Atenção Pré-Natal do Ministério da Saúde foram vetorizadas como fonte documental de referência (Tabela 2). O acervo inclui edições de 2010–2025, e para identificar conflitos no RAG, cada documento foi associado a metadados de ano e origem.

3.2. Ferramentas de IA

A seleção do modelo obedeceu a um critério de viabilidade operacional *on-premise*, com 16GB de VRAM dedicados e janela de contexto configurada em 16.384 *tokens* para RAG. Modelos cujo consumo estimado de VRAM superasse 13GB após quantização Q4 foram descartados para evitar *offloading* de memória, reconhecendo-se que essas estimativas dependem da arquitetura de hardware, *drivers*, mecanismo de inferência e parâmetros de execução.

Tabela 2. Base de conhecimento documental: Manuais e cartilhas.

Título do Documento	Ano	Referência
Guia do Pré-natal do Parceiro [...]	2025	[Brasil. Ministério da Saúde 2025]
Caderneta da Gestante	2024	[Brasil. Ministério da Saúde 2024]
Guia de Atenção à Saúde	2024	[SES-MG 2024]
Manual de Gestação de Alto Risco	2022	[Brasil. Ministério da Saúde 2022]
Ficha Pré-natal	2018	[Brasil. Sistema Único de Saúde 2018]
Atualização em Pré-natal [...]	2014	[SES-SC 2014]
Cadernos de Atenção Básica	2012	[Brasil. Ministério da Saúde 2012a]
Manual Técnico Gestação de Alto Risco	2012	[Brasil. Ministério da Saúde 2012b]
Gestação de Alto Risco	2010	[Brasil. Ministério da Saúde 2010]

Tabela 3. Estimativa teórica de consumo de VRAM.

Modelo	Contexto	Parâmetros	VRAM
Qwen3.6 (Q4)	16.384	35B	~24 GB
Qwen3.5 (Q4)	16.384	27B	~27.4 GB
GPT-OSS (Q4)	16.384	20B	~17.3 GB
Qwen3 (Q4)	16.384	14B	~16.12 GB
Qwen3.5 (Q4)	16.384	9B	~10.51 GB
Qwen3 (Q4)	16.384	8B	~10.41 GB

* Cálculo de VRAM teórico estimado baseado em <https://apxml.com/tools/vram-calculator>.

Para a escolha entre os candidatos compatíveis com 16GB de VRAM sem *offloading* de memória, dentre o conjunto de candidatos, o Qwen3.5 9B foi considerado para combinar menor demanda de memória com uma geração mais recente da família Qwen, cujo *model card* informa suporte a contexto nativo de 262.144 tokens [Qwen Team 2026]. Para complementar o critério de escolha, consultou-se o comparativo público não revisado por pares LLMBase¹. Embora esses resultados não reproduzam a arquitetura local deste trabalho, o comparativo indica vantagem do Qwen3.5 9B sobre o Qwen3 14B em métricas como GPQA (80,6% contra 60,4%) e índice composto de inteligência (32,4 contra 16,2).

A inferência é orquestrada pelo *Ollama* com o modelo Qwen3.5 (9B, quantização Q4) da Alibaba, com os hiperparâmetros da Tabela 1 e a estimativa de consumo de VRAM da Tabela 3, na arquitetura de hardware disponível. A estruturação da base de conhecimento inclui o particionamento semântico (*chunking*) das diretrizes e sua vetorização única, com persistência no armazenamento vetorial.

Na etapa de recuperação, adotou-se *Maximal Marginal Relevance* (MMR) como estratégia de reranqueamento/diversificação dos trechos recuperados. O MMR seleciona iterativamente os *chunks* que apresentam alta similaridade com a consulta, mas penaliza trechos muito semelhantes aos já escolhidos, buscando equilibrar relevância e diversidade no contexto enviado ao modelo [Carbonell and Goldstein 1998]. Essa técnica foi utilizada para reduzir redundância no contexto recuperado, não como mecanismo isolado de resolução de divergências entre edições distintas dos manuais.

4. Metodologia

A pesquisa adota a Engenharia de Software com desenvolvimento ágil (Scrum) para construção do artefato, organizada em cinco frentes integradas: (i) modelagem relacional do prontuário; (ii) *webapp* de gestão e consulta de pacientes; (iii) agente escriba do tipo *overhearing*, contemplando transcrição autorizada da consulta em andamento e sugestão de preenchimentos e condutas sem necessidade de interação explícita; (iv) motor RAG ancorado nas cartilhas do Ministério da Saúde; e (v) assistente local de consulta contextual, operado via chat, voltado a responder perguntas explícitas com base no contexto do prontuário e documentos recuperados.

A arquitetura reflete o isolamento dos módulos em três subredes *Docker*

¹<https://llmbase.ai/compare/qwen3-14b-instruct-reasoning,qwen3-5-9b/>

(frontend-nw, backend-nw e data-nw), conforme a *stack* detalhada na Seção 3 (Materiais).

A sanitização de PII e os controles de minimização de dados seguem o módulo de privacidade descrito anteriormente, fundamentando-se nos requisitos de minimização da LGPD. Todo o áudio capturado é processado localmente e descartado ao final da interação.

A Figura 1 sintetiza o ciclo de vida da transação da consulta médica, estruturado nas seguintes etapas operacionais:




Figura 1. Pipeline arquitetural e ciclo de vida da transação da consulta médica.

- **Captura e transcrição local (STT):** o fluxo de áudio é transcrito em tempo de execução via *Whisper* com diarização.
- **Sanitização de entrada:** o *gateway* remove ou mascara as *PII* na transcrição antes de compor a consulta ao módulo RAG.
- **Recuperação (Retriever):** a busca retorna os trechos relevantes e aplica MMR para diversificar os *chunks* selecionados e reduzir redundâncias no contexto enviado ao modelo.
- **Geração (Generator):** o LLM sintetiza a resposta clínica com hiperparâmetros conservadores, privilegiando a aderência ao contexto recuperado.
- **Apresentação e validação humana:** a interface exibe as sugestões de preenchimento, mantendo a edição manual integralmente disponível.

Para cumprir a restrição de segurança clínica, adota-se uma abordagem baseada no conceito de *Human-in-the-Loop*, onde nenhum dado sugerido pela IA é gravado no

banco de dados sem a confirmação explícita do profissional (US04), garantindo o controle total sobre o registro. A principal ameaça à validade interna é a geração de conteúdo não evidenciado nos protocolos da base de conhecimento, sendo esta mitigada por RAG restrito às diretrizes oficiais e *Human-in-the-Loop*.

A ameaça de exposição de *PII* é mitigada por processamento local em um *gateway* de mascaramento aplicado antes da recuperação e inferência. O anonimizador foi implementado em arquitetura híbrida, combinando regras determinísticas de Expressões Regulares (RegEx) para identificadores brasileiros e um módulo de Reconhecimento de Entidades Nomeadas (NER) especializado em português biomédico. Como modelo de NER, utilizou-se OpenMed/OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1, disponibilizado no Hugging Face [OpenMed Science 2026].

Na implementação do *gateway*, RegEx cobre e-mail, CPF, CNS, telefones, RG e cadeias numéricas longas, contíguas ou separadas, aplicando [EMAIL], [CPF], [CNS], [TELEFONE] e [NUM]. RegEx e NER geram intervalos mesclados antes da máscara; nomes dependem do NER e, se o *sidecar* falhar, uma heurística de duas a quatro palavras capitalizadas, após remover prefixos como “Paciente” e “Nome”, aplica [NOME]. Assim, o modo `regex_only` mantém cobertura determinística de identificadores estruturados.

A modelagem relacional foi derivada da 8ª edição revisada da Caderneta da Gestante, contemplando entidades para paciente, gestação, consultas, sinais vitais, exames, antecedentes, prontuário e registros de atendimento. O DER completo foi disponibilizado como material suplementar no repositório do projeto.

O módulo de transcrição baseado em Faster-Whisper foi integrado ao protótipo para validar a viabilidade técnica do fluxo de captura local de áudio. Contudo, sua avaliação sistemática não compõe o escopo experimental deste trabalho, permanecendo como etapa futura.

5. Solução Proposta

A arquitetura derivou de requisitos funcionais (RF) e histórias de usuário (US) mapeados a riscos clínicos, operacionais e regulatórios. Para RF03/04, o risco de retenção indevida de áudio é tratado por STT local e descarte do áudio após a transcrição, reduzindo a superfície de vazamento. RF05 prevê o uso de RAG restrito, system prompts de escopo limitado e guardrails como mecanismos de contenção de respostas fora do domínio. Contudo, a avaliação funcional identificou falha nessa contenção no caso GT05, indicando que esses mecanismos ainda são insuficientes quando utilizados isoladamente. US04 impede automação indevida: nenhuma sugestão da IA é persistida sem aprovação explícita do profissional, mantendo a decisão final sob sua responsabilidade. US13 reduz a exposição de PII ao modelo por meio do *gateway* de anonimização, de modo que dados em trânsito chegam mascarados à inferência. US05 mitiga atraso na identificação de alto risco com alertas determinísticos baseados em limiares das cartilhas, exibidos na interface da consulta. US06 preserva continuidade do registro físico por exportação em PDF, permitindo uso manual da documentação quando necessário. As interfaces do protótipo de alta fidelidade, incluindo agenda de atendimentos, prontuário consolidado e tela de consulta ativa com o agente Escriba, foram disponibilizadas como material suplementar no repositório do projeto.

6. Avaliação Experimental e Resultados

A avaliação experimental foi conduzida em três frentes complementares: recuperação documental, geração de respostas e segurança do fluxo clínico. O objetivo foi verificar se a arquitetura proposta, baseada em RAG, LLM local e *gateway* de privacidade, consegue recuperar evidências dos manuais oficiais, produzir respostas aderentes aos protocolos e impedir vazamento de informações sensíveis antes da inferência. O conjunto de testes utilizado contém 100 perguntas em português, das quais 90 avaliam aderência a protocolos e 10 são perguntas distratoras (*trap*). A distribuição por dificuldade foi de 42 itens fáceis, 35 médios e 23 difíceis.

Os níveis de dificuldade foram definidos manualmente durante a construção do benchmark: *easy* abrange consultas diretas localizáveis em um documento ou trecho; *medium*, combinação de seções ou encadeamento de condutas no mesmo manual; e *hard*, cenários menos frequentes, exceções, terminologia específica ou perguntas booleanas armadilhosas. A classificação não foi aprendida automaticamente.

Quatro itens classificados como `human_judge` foram mantidos para revisão qualitativa e não compõem o denominador da métrica automática de APR.

Um item é *trap* quando `notes_scoring_pt` contém `tag=trap`; na TFR, `boolean_exact` requer a primeira resposta SIM/NÃO igual ao gabarito e ausência de `must_not_contain_pt`; resposta incorreta ou conteúdo proibido é falha. Como exemplo, Q013 pergunta se a azitromicina substitui a penicilina para tratar sífilis na gestante: a resposta esperada é NÃO, e “azitromicina substitui” ou “eritromicina cura” são proibidas.

6.1. Recuperação Semântica

O módulo de recuperação foi avaliado isoladamente com $top-k=6$ e expansão de consulta ativada. O valor de k foi definido como escolha operacional intermediária, buscando equilibrar cobertura documental e controle de ruído no contexto enviado ao modelo. Foram utilizadas três métricas: *Hit@6*, que verifica se o documento-fonte esperado aparece entre os seis primeiros *chunks*; *Mean Reciprocal Rank* (MRR), que mede quão cedo o primeiro documento correto aparece na lista recuperada. Quanto mais próximo da primeira posição estiver o documento esperado, maior será o valor da métrica, aproximando-se de 1; e *phrase_recall*, que mede a presença das frases esperadas nos trechos recuperados. Além de apoiar a geração de respostas, o RAG acrescenta uma camada de rastreabilidade documental ao sistema, pois permite associar cada resposta aos trechos recuperados, seus documentos de origem e respectivos metadados. Essa característica aumenta a auditabilidade das respostas e favorece a revisão humana, aspecto relevante em sistemas de apoio informacional no contexto médico. A Tabela 4 apresenta os resultados por dificuldade.

Tabela 4. Desempenho do módulo RAG por nível de dificuldade ($n = 100$).

Dificuldade	n	Hit@6 (%)	MRR Médio
Easy	42	76,2%	0,4837
Medium	35	68,6%	0,3633
Hard	23	95,7%	0,6536
Global	100	78,0%	0,4807

O *phrase_recall* médio global foi de 47,1%. Embora os casos encontrados nos itens difíceis representem situações potencialmente mais complexas do ponto de vista clínico, eles frequentemente utilizam terminologia mais específica e menos ambígua, o que favorece a recuperação vetorial. Em contraste, perguntas rotineiras de pré-natal apresentam maior sobreposição semântica entre documentos, aumentando a competição entre trechos similares durante o ranqueamento.

6.2. Geração de Resposta

A geração foi avaliada por meio da Taxa de Aprovação de Respostas (APR) correspondente à proporção de frases obrigatórias aprovadas segundo os critérios de protocolo, calculada sobre itens elegíveis à avaliação automática, e da Taxa de Falha em Perguntas Distratoras (TFR), calculada sobre os itens *trap*. O modelo local Qwen3.5 9B foi executado com e sem RAG para medir o ganho incremental da recuperação. O Gemini-3.1-Flash-Lite foi utilizado apenas como linha de base externa de comparação, recebendo o mesmo contexto recuperado pelo RAG do protótipo, mas sem integrar a arquitetura *on-premise* proposta.

Tabela 5. Desempenho dos modelos na geração de respostas.

Provedor	Modo RAG	APR (%)	TFR (%)
Qwen3.5 9B (Ollama)	Off	53,1% (51/96)	20,0% (2/10)
Qwen3.5 9B (Ollama)	On	57,3% (55/96)	10,0% (1/10)
Gemini-3.1-Flash-Lite	On	61,5% (59/96)	0% (0/10)

A ativação do RAG no modelo local elevou a APR de 53,1% para 57,3% e reduziu a TFR de 20,0% para 10,0%. O ganho é limitado, indicando que a recuperação documental contribui para reduzir respostas inseguras, mas não garante aderência clínica estrita quando o modelo precisa negar condutas, reproduzir termos literais ou resolver conflitos entre documentos. No conjunto total de execuções, foram registradas 3 falhas em itens *trap* e 120 reprovações de protocolo nas 258 avaliações automáticas de frases obrigatórias. Os quatro itens excluídos da avaliação demandam revisão qualitativa da equipe clínica e não entram no denominador da Tabela 5.

6.3. Privacidade, escopo e latência

O módulo de anonimização foi submetido a 50 frases sintéticas, totalizando 76 entidades sensíveis avaliadas, incluindo CPF, Cartão Nacional de Saúde (CNS), e-mail, telefone, nomes completos e cadeias numéricas longas. Não houve vazamento detectado no conjunto testado, conforme a Tabela 6. Esse resultado valida a implementação inicial do mascaramento, mas não elimina a necessidade de testes com variações linguísticas, abreviações e ruído de transcrição.

Tabela 6. Taxa de vazamento de PII por tipo de entidade.

Entidade	n	Leak Rate (%)
CNS	11	0%
CPF	12	0%
E-mail	12	0%
Nome Completo	21	0%
Cadeias Numéricas Longas	8	0%
Telefone	12	0%
Total Global	76	0%

Além das métricas agregadas, aplicou-se o roteiro funcional (GT01-GT05), composto por cinco casos sintéticos para validar comportamentos essenciais do protótipo. Os casos GT01, GT02 e GT03 avaliam respostas clínicas com RAG e LLM em cenários de risco alto extraídos dos manuais protocolares. O GT04 avalia sanitização direta de PII. O GT05 avalia a capacidade de recusar uma requisição fora do escopo de pré-natal.

O roteiro funcional obteve sucesso em quatro dos cinco casos avaliados. Os três casos clínicos com RAG e LLM foram aprovados, assim como o caso de sanitização direta de PII. A falha ocorreu no GT05, no qual a barreira de escopo não conteve adequadamente uma requisição fora do domínio pré-natal. Esse resultado indica que a segurança comportamental não deve depender apenas de *system prompts* e o módulo de privacidade deve incorporar verificações determinísticas ou classificadores de escopo antes da síntese pelo modelo.

Quanto à eficiência computacional, as métricas foram segregadas por configuração para evitar que a linha de base em nuvem distorça a interpretação operacional do protótipo local. A Tabela 7 apresenta os resultados médios.

Tabela 7. Latência média por configuração de execução.

Configuração	Retrieve (ms)	Latência total (s)	TTFT (ms)	tokens/s
Qwen3.5 9B (Ollama)	–	11,71	470,1	32,5
Qwen3.5 9B (Ollama) + RAG on	373,1	15,59	2789,7	32,4
Gemini-3.1-Flash-Lite + RAG on	372,7	4,55	3501,9	360,6

Para o protótipo local, a recuperação vetorial acrescentou aproximadamente 373 ms ao fluxo, enquanto a latência total do Qwen3.5 9B com RAG foi de 15,59 segundos. Portanto, o gargalo operacional permanece na inferência local do LLM e no aumento de contexto provocado pelo RAG, não na busca vetorial. A linha de base externa apresentou maior vazão de geração, mas não representa a premissa de privacidade local da arquitetura proposta. Esse resultado reforça que a adoção em produção de baixo custo ainda é limitada pelos requisitos de hardware, especialmente VRAM, tempo de inferência e estabilidade sob carga.

7. Discussão

Os resultados indicam viabilidade técnica parcial da arquitetura proposta. A combinação de execução local, RAG restrito a documentos oficiais e mascaramento de PII atende ao objetivo de reduzir dependência de nuvem pública e de oferecer um fluxo mais controlável do ponto de vista da LGPD. Os resultados mostram que o protótipo ainda não pode ser interpretado como sistema autônomo de apoio clínico; ele foi concebido como ferramenta assistiva e documental. A APR do modelo local com RAG foi de 57,3%, e a TFR permaneceu em 10,0%; portanto, a recuperação documental melhora o comportamento do LLM, mas não elimina erros em respostas que exigem negação explícita, fidelidade literal ou distinção entre protocolos semanticamente próximos.

O desempenho do RAG com *Hit@6* global de 78,0% demonstra boa capacidade de recuperar ao menos um documento relevante entre os seis primeiros trechos; o *phrase_recall* médio de 47,1% indica que a evidência recuperada nem sempre contém as frases necessárias para satisfazer o critério de resposta. Ou seja, o modelo tende a receber um documento correto, mas sem o trecho suficientemente específico para responder com segurança.

Na análise complementar por dificuldade, que agrega execuções Ollama com RAG ativado e desativado, a APR foi maior em *hard* (72,5%) do que em *easy* (48,8%) e *medium* (52,9%). A mesma hierarquia aparece na recuperação: *hard* obteve *Hit@6* de 95,7% e MRR de 0,6536, acima de *easy* (76,2%; 0,4837) e *medium* (68,6%; 0,3633), sugerindo convergência entre recuperação e geração. O menor resultado em *medium* é compatível com competição semântica em perguntas rotineiras, e não implica ausência de utilidade global do recuperador. Por agregar os dois modos, essa APR não isola o efeito do RAG nem substitui a APR de 57,3% com RAG ativado da Tabela 5. Dos 23 itens *hard*, 10 são *trap*, o que influencia a geração nesse estrato; o *Hit@6* elevado, porém, avalia todas as perguntas classificadas como difíceis.

No desenho do benchmark, itens *easy* e *medium* correspondem majoritariamente a consultas diretas ou encadeamentos de rotina presentes nos protocolos de baixo risco; para profissionais familiarizados com esses fluxos, a busca documental adicional pode ter valor marginal menor. Já os itens *hard* concentram exceções, terminologia de alto risco e condutas menos frequentes descritas nos manuais específicos. [Brasil. Ministério da Saúde 2022] Assim, a convergência observada em *hard* sugere que o protótipo pode se alinhar melhor a um papel assistivo em dúvidas pontuais de maior especificidade, desde que a evidência recuperada permaneça sujeita à revisão humana. Como hipótese de desenho, a latência de aproximadamente 15,59 s com RAG (Tabela 7) pode representar relação custo-benefício informacional mais favorável nessas consultas do que em demandas rotineiras repetitivas; essa preferência não foi medida com usuários.

Em especial, nos itens classificados como difíceis, o módulo RAG atingiu *Hit@6* de 95,7% e MRR de 0,6536, sugerindo maior efetividade em cenários com terminologia protocolar mais específica.

A comparação com o Gemini cria uma nova perspectiva quanto à falha da solução local. O modelo externo atingiu APR superior e TFR nula sob a mesma configuração de RAG, sugerindo que o recuperador atual pode sustentar respostas melhores quando acoplado a modelos mais capazes. O resultado aponta, portanto, para a necessidade de

avaliar modelos locais maiores ou melhor adaptados a terminologia clínica, desde que acompanhados de hardware compatível e controles de privacidade equivalentes.

A ausência de vazamentos de PII no corpus sintético é um resultado positivo, mas sua validade externa é limitada. Nomes brasileiros compostos, abreviações, fala espontânea, erros de transcrição e regionalismos podem gerar padrões fora da distribuição testada. Como o módulo STT não foi avaliado sistematicamente, a transcrição é tratada como dado sensível em trânsito e como pré-preenchimento editável. Essa limitação reforça o papel do fluxo *human-in-the-loop*: o profissional deve validar tanto a informação clínica quanto a integridade dos dados inseridos antes da persistência.

As limitações do estudo decorrem do próprio escopo experimental. A avaliação realizada mede viabilidade arquitetural, privacidade, recuperação documental, aderência automática e comportamento funcional em casos sintéticos; ela não mede eficácia assistencial. Não houve avaliação com gestantes, profissionais de saúde ou dados clínicos reais, logo, os resultados não permitem inferir redução efetiva de carga cognitiva, usabilidade em consulta ou impacto sobre desfechos de cuidado. Além disso, o agente escreva e o módulo STT foram validados apenas quanto à integração funcional ao protótipo, sem métricas formais de qualidade de transcrição, latência ou robustez em ambientes clínicos.

Como trabalhos futuros, recomenda-se refinar a indexação por metadados de versão dos manuais, implementar barreiras determinísticas de escopo antes da geração, avaliar sistematicamente o módulo de transcrição em áudio clínico simulado, comparar modelos locais maiores ou ajustados ao domínio médico e validar o protótipo com profissionais de saúde mediante aprovação ética. Também devem ser mensurados consumo de VRAM, latência e estabilidade sob carga em diferentes configurações de hardware.

8. Conclusão

Este trabalho especificou, implementou e avaliou um sistema protótipo *on-premise* para apoio documental ao pré-natal no contexto do SUS, integrando transcrição local, RAG sobre manuais oficiais, LLM executado via Ollama com revisão humana obrigatória e um *gateway* de anonimização de dados.

A pergunta norteadora foi respondida de forma parcial: a arquitetura mostrou-se tecnicamente viável como base assistiva, auditável e não autônoma, mas os resultados de geração, escopo e latência indicam que o sistema ainda não possui robustez suficiente para uso clínico sem supervisão profissional. A topologia em contêineres deve ser entendida como decisão de privacidade por desenho, não como comprovação de isolamento absoluto, pois não foram realizados testes específicos de segurança de rede.

Na avaliação experimental, o módulo RAG alcançou *Hit@6* global de 78,0% e MRR médio de 0,4807, com *phrase recall* médio de 47,1%, indicando capacidade razoável de recuperar documentos relevantes, embora a evidência recuperada nem sempre contenha o trecho necessário para satisfazer integralmente o critério de resposta. O resultado mais expressivo foi observado nos itens classificados como difíceis, para os quais o módulo RAG atingiu *Hit@6* de 95,7%, sugerindo potencial utilidade em cenários menos rotineiros e com maior especificidade protocolar.

O módulo de privacidade não apresentou vazamento no conjunto sintético de 76 entidades avaliadas, embora esse resultado não substitua testes com fala espontânea,

abreviações, erros de transcrição e maior variação linguística. A latência média de 15,59 segundos no fluxo local com *RAG* evidencia que a inferência local e os requisitos de hardware ainda limitam a adoção de baixo custo em produção. Por fim, a revisão humana obrigatória foi validada como restrição de projeto, pois os resultados reforçam que o sistema deve permanecer assistivo, auditável e não autônomo. A aprovação de quatro dos cinco casos funcionais do roteiro (GT01-GT05) indica coerência funcional inicial, enquanto a falha no GT05 evidencia a necessidade de barreiras de escopo antes da geração via *LLM*.

Como contribuição, o estudo entrega uma arquitetura replicável, um fluxo de privacidade alinhado aos princípios da LGPD e um benchmark inicial reproduzível para avaliação técnica de recuperação, geração, mascaramento de PII, escopo e latência em documentos de pré-natal. Os resultados evidenciam os trade-offs entre execução local, custo computacional e segurança operacional, indicando que avanços em modelos, quantização, aceleração em hardware e técnicas de *RAG* podem tornar esse tipo de sistema mais viável em ambientes reais.

9. Declarações Finais

Os materiais suplementares estão disponíveis no repositório público do projeto: [//github.com/lucaszegrine/sus-prenatal-ai-icei-puc-minas-cc](https://github.com/lucaszegrine/sus-prenatal-ai-icei-puc-minas-cc).

O estudo não envolve participantes humanos, não utiliza dados clínicos reais identificáveis e não foi submetido ao Comitê de Ética em Pesquisa da PUC Minas.

Durante a preparação do texto, foi utilizado o modelo Gemini 3.1 Pro (Google, 04/2026) para revisão gramatical e refinamento de clareza. A ferramenta não foi utilizada para geração de resultados experimentais, análise de resultados ou compartilhamento de dados sensíveis. Todo o conteúdo obtido de forma automatizada foi revisado e editado conforme necessário, sob total responsabilidade dos autores.

Referências

- [Asgari et al. 2025] Asgari, E., Montaña-Brown, N., Dubois, M., Khalil, S., Balloch, J., Yeung, J. A., and Pimenta, D. (2025). A framework to assess clinical safety and hallucination rates of llms for medical text summarisation. *NPJ digital medicine*, 8(1):274.
- [Bernardes et al. 2022] Bernardes, L. S. et al. (2022). Facial expressions of acute pain in 23-week fetus. *Ultrasound in Obstetrics & Gynecology*, 59(3):394–395.
- [Brasil 2018] Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. lei geral de proteção de dados pessoais. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 20 abr. 2026.
- [Brasil. Ministério da Saúde 2010] Brasil. Ministério da Saúde (2010). *Gestação de Alto Risco: Manual Técnico*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012a] Brasil. Ministério da Saúde (2012a). *Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2012b] Brasil. Ministério da Saúde (2012b). *Manual Técnico Gestação de Alto Risco*. Brasília, DF, 5. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2022] Brasil. Ministério da Saúde (2022). *Manual de Gestação de Alto Risco*. Brasília, DF, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2024] Brasil. Ministério da Saúde (2024). *Caderneta da Gestante*. Brasília, DF, 8. ed. rev. edition. Acesso em: 5 fev. 2026.
- [Brasil. Ministério da Saúde 2025] Brasil. Ministério da Saúde (2025). *Guia do Pré-natal do Parceiro para Profissionais de Saúde*. Brasília, DF, 2. ed. edition. Acesso em: 5 fev. 2026.
- [Brasil. Sistema Único de Saúde 2018] Brasil. Sistema Único de Saúde (2018). *Ficha Pré-natal: Acolhimento e Identificação*. Jaguarão, RS. Acesso em: 5 fev. 2026.
- [Cabitza et al. 2022] Cabitza, F., Ciucci, D., Pasi, G., and Viviani, M. (2022). Responsible AI in healthcare. *arXiv preprint*. arXiv:2203.03616v1.
- [Carbonell and Goldstein 1998] Carbonell, J. G. and Goldstein, J. (1998). The use of mmr, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 335–336.
- [Cifuentes et al. 2015] Cifuentes, M., Davis, M., Fernald, D., Gunn, R., Dickinson, P., and Cohen, D. J. (2015). Electronic health record challenges, workarounds, and solutions observed in practices integrating behavioral health and primary care. *The Journal of the American Board of Family Medicine*, 28(Supplement 1):S63–S72.
- [Clusmann et al. 2023] Clusmann, J., Kolbinger, F. R., Muti, H. S., Carrero, Z. I., Eckardt, J.-N., Laleh, N. G., Löffler, C. M. L., Muti, S. C., Quirke, P., Truhn, D., et al. (2023). The future landscape of large language models in medicine. *Communications Medicine*, 3(1):141.
- [Hager et al. 2024] Hager, P., Jungmann, F., Holland, R., Bhagat, K., Hubrecht, I., Knauer, M., Vielhauer, J., Makowski, M., Braren, R., Kaissis, G., et al. (2024). Evaluation

- and mitigation of the limitations of large language models in clinical decision-making. *Nature medicine*, 30(9):2613–2622.
- [Laurenti et al. 2010] Laurenti, R. et al. (2010). Mortes maternas: revisão do fator de correção para os dados oficiais. *Revista Brasileira de Epidemiologia*, 13:1–11.
- [Lewis et al. 2020] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- [Nunes et al. 2017] Nunes, A. D. d. S., Amador, A. E., Dantas, A. P. d. Q. M., Azevedo, U. N. d., and Barbosa, I. R. (2017). Acesso à assistência pré-natal no brasil: análise dos dados da pesquisa nacional de saúde. *Revista Brasileira em Promoção da Saúde*, 30(3).
- [OpenMed Science 2026] OpenMed Science (2026). OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1: Portuguese PII detection model.
- [OWASP GenAI Security Project 2025] OWASP GenAI Security Project (2025). OWASP Top 10 for large language model applications. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>. Versão 2025 (v2.0); CC BY-SA 4.0. Acesso em: 20 abr. 2026.
- [Qwen Team 2026] Qwen Team (2026). Qwen3.5-9B model card. <https://huggingface.co/Qwen/Qwen3.5-9B>. Acesso em: 20 abr. 2026.
- [Rajpurkar et al. 2022] Rajpurkar, P., Chen, E., Banerjee, O., and Topol, E. J. (2022). Ai in health and medicine. *Nature Medicine*, 28(1):31–38.
- [SES-MG 2024] SES-MG (2024). *Guia de Atenção à Saúde da Gestante: Critérios para Estratificação de Acompanhamento da Gestante*. Belo Horizonte, MG, 1. ed. edition. Acesso em: 5 fev. 2026.
- [SES-SC 2014] SES-SC (2014). *Atualização em Pré-natal para Profissionais da Atenção Básica*. Florianópolis, SC, 1. ed. edition. Acesso em: 5 fev. 2026.
- [Sharma 2025] Sharma, C. (2025). Retrieval-augmented generation: A comprehensive survey of architectures, enhancements, and robustness frontiers. *arXiv preprint arXiv:2506.00054*. Preprint.
- [Shneiderman 2021] Shneiderman, B. (2021). Responsible ai: Bridging from ethics to practice. *Communications of the ACM*, 64(8):32–35.