

Caderneta Inteligente da Gestante: utilizando IA generativa com uma abordagem responsável para apoio ao pré-natal

Anonymous Author(s)

RESUMO

In Brazil, prenatal documentation remains fragmented between physical and digital records, which can hinder the continuity and retrieval of information during care. Generative AI can support the completion and integration of these records, but the use of large language models in the public health sector raises privacy, auditability, and hallucination risks. This work proposes an on-premise architecture for an LLM-based prenatal support assistant, integrating local voice transcription, retrieval-augmented generation over Ministry of Health manuals to support source-grounded outputs, and a dedicated privacy gateway to mask personally identifiable information before model inference. Clinical safety is addressed through mandatory human-in-the-loop validation. Despite the operational challenges associated with local deployment, privacy preservation, and controlled model inference, a replicable high-fidelity prototype was developed, focused on privacy, auditability, and human review.

KEYWORDS

Prenatal care, Artificial intelligence, Health information systems, Data privacy, Retrieval-Augmented Generation, LLM applications in healthcare

1 INTRODUÇÃO

A Inteligência Artificial (IA) tem demonstrado potencial transformador na saúde pública, oferecendo soluções para otimização de fluxos de trabalho e suporte à decisão [13, 33–35]. No contexto do atendimento pré-natal, estudos com bases reais de imagem e avaliação fetal têm explorado análises clínicas específicas, como a avaliação de expressões faciais associadas à dor fetal [4, 36], reforçando o interesse em soluções digitais aplicadas ao acompanhamento pré-natal. Contudo, a mortalidade e a morbidade materna no Brasil permanecem como desafios persistentes de saúde pública, associados a desigualdades no acesso à assistência pré-natal e à necessidade de correção dos dados oficiais sobre mortes maternas [21, 29].

A documentação clínica no *Sistema Único de Saúde* (SUS) combina registros em sistemas digitais e instrumentos físicos independentes, como fichas de pré-natal e a Caderneta da Gestante [10, 12]. Essa fragmentação dificulta a integração entre sistemas médicos [16, 20]. Na prática clínica, a dispersão das informações também aumenta o esforço de documentação dos profissionais de saúde [27, 28], especialmente em contextos que exigem monitoramento contínuo, identificação de sinais de risco e consulta frequente a protocolos assistenciais.

Essa demanda torna-se particularmente relevante no pré-natal de alto risco. Segundo as diretrizes dos Manuais de Gestação de

Alto Risco do Ministério da Saúde [8, 9], condições de risco ou morbidades pré-existent exigem estratificação contínua e acesso rápido a protocolos de acompanhamento. Diante do volume de informações envolvido nesse processo, modelos generativos têm sido propostos como assistentes virtuais clínicos para resumo e triagem de dados [17, 33].

No entanto, a implantação irrestrita de Modelos de Linguagem de Grande Escala (LLMs) em cenários públicos de saúde enfrenta barreiras críticas, incluindo o risco de exposição de dados sensíveis (*Personally Identifiable Information* – PII), com potenciais implicações para a conformidade com a Lei Geral de Proteção de Dados (LGPD) [5, 31]. Além disso, estudos apontam limitações no uso autônomo desses modelos em decisões clínicas, incluindo falhas em seguir instruções e sensibilidade ao contexto fornecido [18], bem como risco de geração de respostas não fundamentadas ou clinicamente inadequadas [3].

Diante dessas limitações, este trabalho propõe a especificação, implementação e avaliação de uma plataforma digital *on-premise* para apoio documental ao pré-natal, com foco no registro clínico durante a própria consulta, sem substituir a validação profissional. A abordagem proposta combina transcrição de voz para texto (*Speech-to-Text*), recuperação aumentada (RAG) por documentos oficiais do Ministério da Saúde, mascaramento de PII, e validação profissional obrigatória. O trabalho também avalia em que medida modelos menores, executados localmente, podem alcançar desempenho próximo ao de modelos fechados de maior porte nessa tarefa, dentro de limites computacionais razoáveis para uso cotidiano. Essa comparação é relevante porque pode reduzir a dependência de serviços externos no processamento de áudio e dados textuais sensíveis.

Embora a adoção de RAG busque aproximar as respostas dos protocolos utilizados como base documental, ela não elimina a necessidade de avaliar a aderência das saídas geradas. Da mesma forma, o mascaramento de PII antes da inferência reduz a exposição de dados sensíveis, mas não substitui mecanismos de validação e controle ao longo do fluxo. Por isso, a arquitetura proposta é concebida como um sistema assistivo e não autônomo, no qual o modelo generativo não recebe autonomia decisória nem persiste informações sem validação profissional. A partir dessa delimitação, este trabalho baseia-se na seguinte pergunta norteadora: *Como especificar, implementar e avaliar um protótipo on-premise para apoio documental ao pré-natal a partir de protocolos públicos, sem atribuir autonomia decisória ao modelo generativo?* Essa pergunta norteadora desdobra-se nas seguintes questões de pesquisa, identificadas como RQ1–RQ5 ao longo do artigo:

- **RQ1:** Como estruturar uma arquitetura local em contêineres que reduza o risco de exposição de áudio ou dados textuais sensíveis?
- **RQ2:** Qual é o desempenho do módulo RAG na recuperação de documentos e trechos relevantes dos manuais oficiais de pré-natal?

- **RQ3:** Qual é a aderência das respostas geradas por um LLM local aos protocolos de atendimento pré-natal no SUS?
- **RQ4:** Em que medida um anonimizador de dados pessoais sensíveis mascara entidades antes da inferência pelo modelo generativo?
- **RQ5:** Quais são os custos de latência associados à execução local em comparação com uma linha de base externa?

O objetivo geral deste trabalho é especificar, implementar e avaliar uma plataforma digital *on-premise* para apoio documental ao pré-natal, integrando um LLM fundamentado por RAG e mecanismos de mascaramento de PII, com ênfase em explicabilidade, privacidade por desenho, auditabilidade e alinhamento às diretrizes públicas de saúde. Para atingir esse objetivo, delineiam-se os seguintes objetivos específicos:

- (1) Desenvolver um protótipo funcional voltado à consulta assistida de informações de pré-natal, mantendo revisão humana obrigatória;
- (2) Implementar um módulo de anonimização dedicado ao mascaramento e sanitização de PII brasileiras;
- (3) Estruturar a recuperação de conhecimento com base em documentos públicos oficiais;
- (4) Avaliar o desempenho do protótipo por meio de métricas de recuperação, aderência automática de respostas em testes sintéticos e análise de latência.
- (5) Analisar os ganhos e perdas entre privacidade local, custo computacional, latência e viabilidade de implantação em ambientes de produção.

O artigo está organizado da seguinte forma: a Seção 2 apresenta os fundamentos teóricos que orientam a proposta; as Seções 3 e 4 descrevem os materiais, o ambiente experimental, a arquitetura e as interfaces da plataforma; e a Seção 5 apresenta os experimentos conduzidos para responder às perguntas de pesquisa. Por fim, a Seção 6 discute os resultados obtidos, e a Seção 7 sintetiza as conclusões do estudo.

2 REFERENCIAL TEÓRICO

Sistemas de IA aplicados a contextos clínicos exigem mecanismos explícitos de supervisão, responsabilização e controle de uso. Em abordagens centradas no humano, a automação deve preservar a agência do profissional, tornar suas limitações visíveis e evitar que recomendações algorítmicas sejam incorporadas ao fluxo assistencial sem revisão adequada [13, 40]. Esses princípios são particularmente relevantes para sistemas generativos, que podem ocultar incertezas, omissões ou inconsistências na resposta produzida.

Modelos de Linguagem de Grande Escala baseados apenas em conhecimento paramétrico têm limitações para recuperar informações atualizadas, indicar a origem de uma afirmação e manter aderência a documentos normativos específicos [25]. A técnica de *Retrieval-Augmented Generation* (RAG) aborda parte desse problema ao recuperar evidências externas em tempo de inferência e condicionar a geração textual ao contexto documental recuperado [22]. Em saúde e biomedicina, revisões recentes indicam que RAG pode melhorar a fundamentação factual das respostas, mas sua eficácia depende da qualidade da recuperação, da fidelidade ao contexto, da robustez frente a ruído documental, da latência e dos critérios utilizados para avaliar as saídas geradas [1, 39].

O uso de RAG em bases normativas e diretrizes clínicas aproxima modelos generativos de fontes documentais controladas, o que é relevante em tarefas nas quais a resposta deve estar vinculada a protocolos específicos. Estudos aplicados a protocolos e diretrizes médicas sugerem que a recuperação de trechos normativos pode apoiar a consistência das respostas, desde que o corpus, a indexação e os critérios de avaliação sejam adequados ao domínio [19]. De forma relacionada, trabalhos recentes também têm avaliado RAG em cenários clínicos com modelos localmente implantáveis. Wada et al. [43], por exemplo, avaliam um modelo Llama executado localmente com RAG em uma tarefa de consulta sobre contraste radiológico, comparando seu desempenho com modelos fechados acessados em nuvem. Outros trabalhos aproximam o RAG de tarefas clínicas complementares. Wolk [44] avalia variantes de RAG para apoio à decisão clínica em implantação *on-premises*, enquanto Lopez et al. [24] propõem um pipeline de recuperação aumentada por entidades clínicas para extração de informações em notas clínicas.

A contribuição deste trabalho, porém, não se limita a avaliar se um modelo local com RAG responde adequadamente a uma consulta clínica especializada. O foco está em integrar esse tipo de modelo a um fluxo documental de pré-natal no SUS, no qual a resposta gerada é apenas uma etapa intermediária entre a recuperação de evidências oficiais, o preenchimento provisório de campos clínicos e a validação profissional antes da persistência no prontuário. Essa diferença é relevante porque desloca a avaliação de um cenário de pergunta e resposta para uma arquitetura assistiva com controle de privacidade, rastreabilidade documental e separação explícita entre sugestão algorítmica, decisão profissional e registro final.

Essa separação é necessária porque métricas automáticas isoladas não asseguram, por si só, a segurança, a utilidade e a adequação clínica das respostas geradas por LLMs em saúde [42]. Em sistemas de apoio documental, uma resposta formalmente plausível pode ainda estar incompleta, fora de contexto ou inadequada para incorporação ao registro clínico. Por isso, a revisão profissional obrigatória é tratada como requisito de segurança e de delimitação da autonomia do sistema, não apenas como etapa de interface.

Além dos desafios de aderência clínica, a integração de LLMs a fluxos assistenciais amplia riscos de segurança e privacidade. O *OWASP Top 10 for Large Language Model Applications* mapeia ameaças como injeção de *prompt*, vazamento de dados sensíveis e manipulação de conteúdos recuperados por aplicações baseadas em LLMs [31]. Revisões sobre privacidade em LLMs também destacam riscos de exposição, memorização ou reprodução de dados sensíveis, especialmente em domínios como saúde [15, 45]. Esses riscos tornam relevantes estratégias de minimização de dados antes da inferência, incluindo detecção e mascaramento de informações pessoalmente identificáveis.

A Tabela 1 sintetiza esse posicionamento em relação aos estudos mais próximos. Em conjunto, esses trabalhos mostram avanços importantes em RAG clínico, execução local, diretrizes médicas, extração de informações clínicas e mitigação de alucinações. Contudo, não tratam esses elementos como partes de um mesmo fluxo documental assistivo. Este trabalho se insere nessa lacuna ao articular documentos oficiais brasileiros, modelos locais, mascaramento de PII e validação profissional obrigatória em uma arquitetura voltada ao apoio documental ao pré-natal no SUS.

Tabela 1: Dimensões exploradas por estudos relacionados.

Referência	Escopo	Saída do modelo	RAG	Execução local	Corpus normativo	Mascaramento de PII	Persistência validada no registro
Ke et al. [19]	Diretrizes clínicas pré-operatórias	Resposta a consulta baseada em diretrizes	✓	Parcial	✓	Não avaliado	Não avaliado
Wada et al. [43]	Consulta sobre contraste radiológico	Resposta clínica especializada	✓	✓	Parcial	Não avaliado	Não avaliado
Lopez et al. [24]	Extração de informações em notas clínicas	Variáveis clínicas extraídas de registros textuais	✓	Não avaliado	Não avaliado	Não avaliado	Não avaliado
Wolk [44]	Apoio à decisão clínica com RAG on-premises	Resposta de apoio à decisão baseada em vinhetas clínicas	✓	✓	Parcial	Não avaliado	Não avaliado
Este trabalho	Apoio documental ao pré-natal no SUS	Sugestão provisória vinculada ao registro	✓	✓	✓	✓	✓

Nota: “Não avaliado” indica que a dimensão não aparece como eixo de avaliação ou contribuição principal no estudo citado e não implica ausência absoluta de discussão sobre o tema. No caso de privacidade, a tabela distingue discussões gerais sobre implantação local, dados desidentificados ou segurança operacional de mecanismos específicos de mascaramento de PII antes da inferência. “Parcial” indica que a dimensão aparece de forma relacionada, mas não como tema central ou com o mesmo escopo operacional adotado neste trabalho.

3 MATERIAIS

Nesta seção, são detalhados os componentes que estruturam o sistema, incluindo os requisitos de *hardware* para execução local, os *frameworks* de desenvolvimento, as bases de dados utilizadas e as ferramentas de Inteligência Artificial implementadas. A escolha do modelo obedeceu ao critério de viabilidade operacional local, sendo o protótipo executado em ambiente com CPU Intel i7-14700K, 32GB de RAM e GPU Nvidia RTX 5060 Ti com 16GB de VRAM. Embora o model card do Qwen3.5 9B indique suporte a contexto padrão de 262.144 tokens, adotou-se uma janela operacional reduzida de 16.384 tokens no protótipo, em função das restrições locais de VRAM, latência e estabilidade de inferência [32]. A escolha do Qwen3.5 9B quantizado em Q4 decorreu da compatibilidade com a VRAM disponível, evitando *offloading* para RAM/CPU e aumento expressivo do tempo até o primeiro token (TTFT).

O ambiente adota *TypeScript* como linguagem principal. O *backend* foi desenvolvido em *Node.js* utilizando o micro-*framework* Hono e o *frontend* foi estruturado em React, empregando Vite e TailwindCSS. A execução em contêineres *Docker* contribui para segmentação lógica e isolamento operacional, reduzindo a exposição de PII em caso de comprometimento. Para transcrição, integra-se o *Faster-Whisper* com processamento local e descarte imediato do stream de áudio, evitando o envio a terceiros e reduzindo a superfície de vazamento. [41] A diarização é realizada localmente pelo pipeline *pyannote/speaker-diarization-3.1*, responsável por segmentar o áudio em turnos associados a rótulos anônimos de locutor [?].

A orquestração do LLM clínico ocorre via *Ollama*; para apoio à decisão, empregam-se hiperparâmetros conservadores (Tabela 2) para reduzir a variabilidade, favorecendo a aderência ao contexto recuperado.

3.1 Base de Dados

A camada transacional (cadastros e triagens) utiliza *PostgreSQL*, gerenciado via *Prisma ORM*. As Cartilhas de Atenção Pré-Natal do Ministério da Saúde foram vetorizadas como fonte documental de referência (Tabela 3). O acervo inclui edições de 2010–2025 e para

Tabela 2: Hiperparâmetros de inferência (Ollama) e RAG.

LLM (Qwen3.5)		RAG & Chunking	
num_ctx	16.384	embedding_model	nomic-embed-text
num_batch	256	chunk_max_chars	900
temperature	0.1	max_chunks	6
top_p	0.9	rerank_enabled	True

mitigar conflitos no RAG, cada documento foi associado a metadados de ano e origem, permitindo rastreabilidade das respostas geradas.

3.2 Ferramentas de IA

A seleção do modelo obedeceu a um critério de viabilidade operacional *on-premise*, com 16GB de VRAM dedicados e janela de contexto configurada em 16.384 *tokens* para RAG. Modelos cujo consumo estimado de VRAM superasse 13GB após quantização Q4 foram descartados para evitar *offloading* de memória, reconhecendo-se que essas estimativas são teóricas e dependem da arquitetura de hardware, *drivers*, mecanismo de inferência e parâmetros de execução [2].

Tabela 3: Base de conhecimento documental: Manuais e cartilhas.

Título do Documento	Ano	Referência
Guia do Pré-natal do Parceiro [...]	2025	[11]
Caderneta da Gestante	2024	[10]
Guia de Atenção à Saúde	2024	[37]
Manual de Gestação de Alto Risco	2022	[9]
Ficha Pré-natal	2018	[12]
Atualização em Pré-natal [...]	2014	[38]
Cadernos de Atenção Básica	2012	[7]
Manual Técnico Gestação de Alto Risco	2012	[8]
Gestação de Alto Risco	2010	[6]

Tabela 4: Estimativa teórica de consumo de VRAM.

Modelo	Contexto	Parâmetros	VRAM
Qwen3.6 (Q4)	16.384	35B	~24 GB
Qwen3.5 (Q4)	16.384	27B	~27.4 GB
GPT-OSS (Q4)	16.384	20B	~17.3 GB
Qwen3 (Q4)	16.384	14B	~16.12 GB
Qwen3.5 (Q4)	16.384	9B	~10.51 GB
Qwen3 (Q4)	16.384	8B	~10.41 GB

* Cálculo de VRAM teórico estimado baseado em <https://apxml.com/tools/vram-calculator>.

Para a escolha entre os candidatos compatíveis com 16GB de VRAM sem *offloading* de memória, dentre o conjunto de candidatos, o Qwen3.5 9B foi considerado para combinar menor demanda de memória com uma geração mais recente da família Qwen, cujo *model card* informa suporte a contexto nativo de 262.144 tokens [32]. Para complementar o critério de escolha, consultou-se o comparativo público não revisado por pares LLMBase [23]. Embora esses resultados não reproduzam a arquitetura local deste trabalho, o comparativo indica vantagem do Qwen3.5 9B sobre o Qwen3 14B em métricas como GPQA (80,6% contra 60,4%) e índice composto de inteligência (32,4 contra 16,2).

A inferência é orquestrada pelo *Ollama* com o modelo Qwen3.5 (9B, quantização Q4) da Alibaba, parametrizado para mitigar alucinações (Tabela 4) na arquitetura de hardware disponível. A estruturação da base de conhecimento inclui o particionamento semântico (*chunking*) das diretrizes e sua vetorização única, com persistência no armazenamento vetorial.

Na etapa de recuperação, adotou-se *Maximal Marginal Relevance* (MMR) como estratégia de ranqueamento/diversificação dos trechos recuperados. O MMR seleciona iterativamente os *chunks* que apresentam alta similaridade com a consulta, mas penaliza trechos muito semelhantes aos já escolhidos, buscando equilibrar relevância e diversidade no contexto enviado ao modelo [14]. Essa técnica foi utilizada para reduzir redundância no contexto recuperado, não como mecanismo isolado de resolução de divergências entre edições distintas dos manuais.

4 METODOLOGIA

A pesquisa adota a Engenharia de Software com desenvolvimento ágil (Scrum) para construção do artefato, organizada em cinco frentes integradas: (i) modelagem relacional do prontuário; (ii) *WebApp* de gestão e consulta de pacientes; (iii) agente escriba do tipo *overhearing*, contemplando transcrição autorizada da consulta em andamento e sugestão de preenchimentos e condutas sem necessidade de interação explícita; (iv) motor RAG ancorado nas cartilhas do Ministério da Saúde; e (v) assistente local de consulta contextual, operado via chat, voltado a responder perguntas explícitas com base no contexto do prontuário e documentos recuperados.

A arquitetura reflete o isolamento dos módulos em três subredes *Docker* (frontend-nw, backend-nw e data-nw), conforme a *stack* detalhada na Seção 3 (Materiais).

A sanitização de PII e os controles de minimização de dados seguem o módulo de privacidade descrito anteriormente, fundamentando-se nos requisitos de minimização da LGPD apresentados na Seção 2. Todo o áudio capturado é processado localmente e descartado ao final da interação.

A Figura 1 sintetiza o ciclo de vida da transação da consulta médica, estruturado nas seguintes etapas operacionais:

- **Captura e transcrição local (STT):** o fluxo de áudio é transcrito em tempo de execução via *Whisper* com diarização via *pyannote/speaker-diarization-3.1*.
- **Sanitização de entrada:** o *gateway* remove ou mascara as PII na transcrição antes de compor a consulta ao módulo RAG.
- **Recuperação (Retriever):** a busca retorna os trechos relevantes e aplica MMR para diversificar os *chunks* selecionados e reduzir redundâncias no contexto enviado ao modelo.
- **Geração (Generator):** o LLM sintetiza a resposta clínica com hiperparâmetros conservadores, privilegiando a aderência ao contexto recuperado.
- **Apresentação e validação humana:** a interface exibe as sugestões de preenchimento, mantendo a edição manual integralmente disponível.

Para cumprir a restrição de segurança clínica, adota-se uma abordagem baseada no conceito de *Human-in-the-Loop*, onde nenhum dado sugerido pela IA é gravado no banco de dados sem a confirmação explícita do profissional (US04). A principal ameaça à validade interna é a geração de conteúdo não evidenciado nos protocolos da base de conhecimento, sendo esta mitigada por RAG restrito às diretrizes oficiais e *Human-in-the-Loop*.

A ameaça de exposição de PII é mitigada por processamento local em um *gateway* de mascaramento aplicado antes da recuperação e inferência. O anonimizador foi implementado em arquitetura híbrida, combinando regras determinísticas de Expressões Regulares (RegEx) para identificadores brasileiros e um módulo de Reconhecimento de Entidades Nomeadas (NER) especializado em português biomédico. Como modelo de NER, utilizou-se o OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1 [30].

A modelagem relacional foi derivada da 8ª edição revisada da Caderneta da Gestante, contemplando entidades para paciente, gestão, consultas, sinais vitais, exames, antecedentes, prontuário e registros de atendimento. O DER completo foi disponibilizado como material suplementar no repositório do projeto.

O módulo de transcrição baseado em *Faster-Whisper* foi integrado ao protótipo para validar a viabilidade técnica do fluxo de captura local de áudio. Contudo, sua avaliação sistemática não compõe o escopo experimental deste trabalho, permanecendo como etapa futura.

4.1 Solução Proposta

A arquitetura derivou de requisitos funcionais (RF) e histórias de usuário (US) mapeados a riscos clínicos, operacionais e regulatórios. A Tabela 5 resume essa relação, demonstrando como as ferramentas teóricas abordadas foram convertidas em funcionalidades práticas no protótipo. As interfaces do protótipo de alta fidelidade, incluindo agenda de atendimentos, prontuário consolidado e tela de consulta




Figura 1: Pipeline arquitetural e ciclo de vida da transação da consulta médica.

ativa com o agente Escriba, foram disponibilizadas como material suplementar no repositório do projeto.

5 AVALIAÇÃO EXPERIMENTAL E RESULTADOS

A avaliação experimental foi conduzida em três frentes complementares: recuperação documental, geração de respostas e segurança do fluxo clínico, associadas às RQ2, RQ3 e RQ4, respectivamente. A RQ1 é avaliada de forma complementar pelos testes funcionais de segurança do fluxo, enquanto a RQ5 é tratada na análise de latência. O objetivo foi verificar se a arquitetura proposta, baseada em RAG, LLM local e gateway de privacidade, consegue recuperar evidências dos manuais oficiais, produzir respostas aderentes aos protocolos e mitigar vazamento de informações sensíveis antes da inferência. O conjunto de testes utilizado contém 100 perguntas em português, das quais 90 avaliam aderência a protocolos e 10 são perguntas distratoras (trap). A distribuição por dificuldade foi de 42 itens fáceis, 35 médios e 23 difíceis. Os níveis de dificuldade foram definidos manualmente durante a construção do benchmark. Questões fáceis correspondem a consultas diretas cuja resposta pode ser localizada em um único documento ou trecho protocolar. Questões de dificuldade média exigem combinar múltiplas informações presentes em diferentes seções de um mesmo manual ou em documentos distintos. Questões difíceis envolvem cenários menos frequentes, exceções protocolares ou situações que demandam maior especificidade terminológica para recuperação da evidência correta. Quatro

itens classificados como human_judge foram mantidos para revisão qualitativa e não compõem o denominador da métrica automática de APR. Este sistema de avaliação foi inspirado por práticas da indústria para avaliação de agentes de IA, como as avaliações de agentes do Microsoft Copilot Studio [26].

5.1 Recuperação Semântica

O módulo de recuperação, correspondente à RQ2, foi avaliado isoladamente com top-k=6 e expansão de consulta ativada. O valor de k foi definido como escolha operacional intermediária, buscando equilibrar cobertura documental e controle de ruído no contexto enviado ao modelo. Foram utilizadas três métricas: Hit@6, que verifica se o documento-fonte esperado aparece entre os seis primeiros chunks; Mean Reciprocal Rank (MRR), que mede quão cedo o primeiro documento correto aparece na lista recuperada. Quanto mais próximo da primeira posição estiver o documento esperado, maior será o valor da métrica, aproximando-se de 1; e phrase_recall, que mede a presença das frases esperadas nos trechos recuperados. Além de apoiar a geração de respostas, o RAG acrescenta uma camada de rastreabilidade documental ao sistema, pois permite associar cada resposta aos trechos recuperados, seus documentos de origem e respectivos metadados. Essa característica aumenta a auditabilidade das respostas e favorece a revisão humana, aspecto relevante em sistemas de apoio informacional no contexto médico. A Tabela 6 apresenta os resultados por dificuldade.

Tabela 5: Requisitos, riscos mitigados e mecanismos de controle.

RF/US	Risco	Decisão de design	Mitigação esperada
RF03/04	Retenção indevida de áudio.	STT local; áudio não persistido.	Reduz superfície de vazamento.
RF05	Alucinação em conduta clínica.	RAG restrito a manuais; <i>system prompts</i> com escopo limitado; <i>guardrails</i> para recusa fora do contexto recuperado	Respostas embasadas em protocolo oficial.
US04	Automação indevida.	Bloqueio de persistência sem aprovação; <i>guardrails</i> para exigir validação humana	Decisão final sob responsabilidade do profissional.
US13	Exposição de PII ao modelo.	<i>Gateway</i> de anonimização.	Dados em trânsito anonimizados
US05	Atraso na identificação de alto risco.	Alertas determinísticos por limiares das cartilhas.	Sinalização visual imediata na consulta
US06	Descontinuidade do registro físico.	Exportação PDF.	Continuidade do cuidado manual

Tabela 6: Desempenho do módulo RAG por nível de dificuldade ($n = 100$).

Dificuldade	n	Hit@6 (%)	MRR Médio
Easy	42	76,2%	0,4837
Medium	35	68,6%	0,3633
Hard	23	95,7%	0,6536
Global	100	78,0%	0,4807

O *phrase_recall* médio global foi de 47,1%. Embora os casos contrários nos itens difíceis representem situações potencialmente mais complexas do ponto de vista clínico, eles frequentemente utilizam terminologia mais específica e menos ambígua, o que favorece a recuperação vetorial. Em contraste, perguntas rotineiras de pré-natal apresentam maior sobreposição semântica entre documentos, aumentando a competição entre trechos similares durante o ranqueamento.

5.2 Geração de Resposta

A geração de respostas, eixo da RQ3, foi avaliada pela Taxa de Aprovação de Respostas (APR), que representa a proporção de itens elegíveis aprovados pelos critérios automáticos, e pela Taxa de Falha em Perguntas Distratoras (TFR), calculada exclusivamente sobre os itens *trap*. Cada item é formado por uma pergunta e pela resposta produzida pelo modelo. As frases obrigatórias definem os critérios de aprovação. Um item é aprovado somente quando atende a todos os critérios automáticos aplicáveis.

Nos itens *trap*, a APR verifica se a resposta apresenta o comportamento esperado pela suíte. A TFR mede a emissão de conteúdo proibido. Portanto, um item *trap* pode ser reprovado na APR sem aumentar a TFR. Em cada configuração, a APR considera 96 itens elegíveis: 86 itens protocolários e 10 itens *trap*.

O modelo local Qwen3.5 9B foi executado com e sem RAG para medir o ganho incremental da recuperação. O Gemini-3.1-Flash-Lite foi utilizado apenas como linha de base externa de comparação, recebendo o mesmo contexto recuperado pelo RAG do protótipo, mas sem integrar a arquitetura *on-premise* proposta.

A ativação do RAG no modelo local elevou a APR de 53,1% para 57,3% e reduziu a TFR de 20,0% para 10,0%. O ganho é limitado,

Tabela 7: Desempenho dos modelos na geração de respostas.

Provedor	Modo RAG	APR (%)	TFR (%)
Qwen3.5 9B (Ollama)	Off	53,1% (51/96)	20,0% (2/10)
Qwen3.5 9B (Ollama)	On	57,3% (55/96)	10,0% (1/10)
Gemini-3.1-Flash-Lite	On	61,5% (59/96)	0% (0/10)

indicando que a recuperação documental contribui para reduzir respostas inseguras, mas não garante aderência clínica estrita quando o modelo precisa negar condutas, reproduzir termos literais ou resolver conflitos entre documentos. Nas três configurações, a APR totalizou 165 aprovações e 123 reprovações em 288 avaliações automáticas. A TFR registrou três falhas nos 30 itens *trap*. Como os itens *trap* também compõem a APR, as falhas da TFR não são somadas às reprovações da APR. Os quatro itens *human_judge* demandam revisão qualitativa da equipe clínica e não entram nos denominadores apresentados.

5.3 Privacidade, escopo e latência

A avaliação do mascaramento de PII, correspondente à RQ4, submeteu o módulo de anonimização a 50 frases sintéticas, totalizando 76 entidades sensíveis avaliadas, incluindo CPF, Cartão Nacional de Saúde (CNS), e-mail, telefone, nomes completos e cadeias numéricas longas. Não houve vazamento detectado no conjunto testado, conforme a Tabela 8. Esse resultado valida a implementação inicial do mascaramento, mas não elimina a necessidade de testes com variações linguísticas, abreviações e ruído de transcrição.

Tabela 8: Taxa de vazamento de PII por tipo de entidade.

Entidade	n	Leak Rate (%)
CNS	11	0%
CPF	12	0%
E-mail	12	0%
Nome Completo	21	0%
Cadeias Numéricas Longas	8	0%
Telefone	12	0%
Total Global	76	0%

Tabela 9: Latência média por configuração de execução.

Configuração	Recuperação (ms)	Latência total (s)	TTFT (ms)	tokens/s
Qwen3.5 9B (Ollama)	–	11,71	470,1	32,5
Qwen3.5 9B (Ollama) + RAG on	373,1	15,59	2789,7	32,4
Gemini-3.1-Flash-Lite + RAG on	372,7	4,55	3501,9	360,6

Além das métricas agregadas, o roteiro funcional (GT01-GT05) avaliou aspectos operacionais ligados à RQ1, com cinco casos sintéticos voltados a comportamentos essenciais do protótipo. Os casos GT01, GT02 e GT03 avaliam respostas clínicas com RAG e LLM em cenários de risco alto extraídos dos manuais protocolares. O GT04 avalia sanitização direta de PII. O GT05 avalia a capacidade de recusar uma requisição fora do escopo de pré-natal.

O roteiro funcional obteve sucesso em quatro dos cinco casos avaliados. Os três casos clínicos com RAG e LLM foram aprovados, assim como o caso de sanitização direta de PII. A falha ocorreu no GT05, no qual a barreira de escopo não conteve adequadamente uma requisição fora do domínio pré-natal. Esse resultado indica que a segurança comportamental não deve depender apenas de *system prompts* e o módulo de privacidade deve incorporar verificações determinísticas ou classificadores de escopo antes da síntese pelo modelo.

A RQ5 foi analisada a partir das métricas de eficiência computacional, segregadas por configuração para evitar que a linha de base em nuvem distorça a interpretação operacional do modelo local. A Tabela 9 apresenta os resultados médios encontrados.

Para o protótipo local, a recuperação vetorial acrescentou aproximadamente 373 ms ao fluxo, enquanto a latência total do Qwen3.5 9B com RAG foi de 15590,1 ms. Portanto, o gargalo operacional permanece na inferência local do LLM e no aumento de contexto provocado pelo RAG, não na busca vetorial. A linha de base externa apresentou maior vazão de geração, mas não representa a premissa de privacidade local da arquitetura proposta. Esse resultado reforça que a adoção em produção de baixo custo ainda é limitada pelos requisitos de hardware, especialmente VRAM, tempo de inferência e estabilidade sob carga.

6 DISCUSSÃO

Os resultados indicam viabilidade técnica parcial da arquitetura proposta. A combinação de execução local, RAG restrito a documentos oficiais e mascaramento de PII atende ao objetivo de reduzir dependência de nuvem pública e de oferecer um fluxo mais controlável do ponto de vista da LGPD. Os resultados mostram que o protótipo não pode ser interpretado como sistema autônomo de apoio clínico. Este foi concebido como ferramenta assistiva e documental. A APR do modelo local com RAG foi de 57,3%, e a TFR permaneceu em 10,0%; portanto, a recuperação documental melhora o comportamento do LLM, mas não elimina erros em respostas que exigem negação explícita, fidelidade literal ou distinção entre protocolos semanticamente próximos.

O desempenho do RAG com *Hit@6* global de 78,0% demonstra boa capacidade de recuperar ao menos um documento relevante entre os seis primeiros trechos, o *phrase_recall* médio de 47,1% indica

que a evidência recuperada nem sempre contém as frases necessárias para satisfazer o critério de resposta. Ou seja, o modelo tende a receber um documento correto, mas sem o trecho suficientemente específico para responder com segurança. Esse comportamento é compatível com a assimetria observada por dificuldade: itens difíceis, frequentemente associados a termos técnicos de alto risco, foram mais bem recuperados do que itens médios, nos quais há maior competição lexical entre manuais de pré-natal de rotina. Em especial, nos itens classificados como difíceis, o módulo RAG atingiu *Hit@6* de 95,7% e *MRR* de 0,6536, sugerindo maior efetividade em cenários com terminologia protocolar mais específica.

A comparação com o Gemini explicita as limitações da solução local. O modelo externo atingiu APR superior e TFR nula sob a mesma configuração de RAG, sugerindo que o recuperador atual pode sustentar respostas melhores quando acoplado a modelos mais capazes. O resultado aponta, portanto, para a necessidade de avaliar modelos locais maiores ou melhor adaptados a terminologia clínica, desde que acompanhados de hardware compatível e controles de privacidade equivalentes.

A ausência de vazamentos de PII no corpus sintético é um resultado positivo, mas sua validade externa é limitada. Nomes brasileiros compostos, abreviações, fala espontânea, erros de transcrição e regionalismos podem gerar padrões fora da distribuição testada. Como o módulo STT não foi avaliado sistematicamente, a transcrição é tratada como dado sensível em trânsito e como pré-preenchimento editável. Essa limitação reforça o papel do fluxo *human-in-the-loop*: o profissional deve validar tanto a informação clínica quanto a integridade dos dados inseridos antes da sua respectiva persistência.

As limitações do estudo decorrem do próprio escopo experimental. A avaliação realizada mede viabilidade arquitetural, privacidade, recuperação documental, aderência automática e comportamento funcional em casos sintéticos; ela não mede eficácia assistencial. Não houve avaliação com gestantes, profissionais de saúde ou dados clínicos reais, logo, os resultados não permitem inferir redução efetiva de carga cognitiva, usabilidade em consulta ou impacto sobre desfechos de cuidado. Além disso, o agente escreva e o módulo STT foram validados apenas quanto à integração funcional ao protótipo, sem métricas formais de qualidade de transcrição, latência ou robustez em ambientes clínicos.

Como trabalhos futuros, recomenda-se refinar a indexação por metadados de versão dos manuais, implementar barreiras determinísticas de escopo antes da geração, avaliar sistematicamente o módulo de transcrição em áudio clínico simulado, comparar modelos locais maiores ou ajustados ao domínio médico e validar o protótipo com profissionais de saúde mediante aprovação ética. Também devem ser mensurados consumo de VRAM, latência e estabilidade sob carga em diferentes configurações de hardware.

7 CONCLUSÃO

Este trabalho especificou, implementou e avaliou um sistema protótipo *on-premise* para apoio documental ao pré-natal no contexto do SUS, integrando transcrição local, RAG sobre manuais oficiais, LLM executado via Ollama com revisão humana obrigatória e um *gateway* de anonimização de dados.

A pergunta norteadora foi respondida de forma parcial: a arquitetura mostrou-se tecnicamente viável como base assistiva, auditável e não autônoma, mas os resultados de geração, escopo e latência indicam que o sistema ainda não possui robustez suficiente para uso clínico sem supervisão profissional. A topologia em contêineres deve ser entendida como decisão de privacidade por desenho, não como comprovação de isolamento absoluto, pois não foram realizados testes específicos de segurança de rede.

Na avaliação experimental, o módulo RAG alcançou *Hit@6* global de 78,0% e MRR médio de 0,4807, mas o *phrase_recall* médio de 47,1%, indicando capacidade razoável de recuperar documentos relevantes, embora o *phrase_recall* mostre que a evidência recuperada nem sempre contém o trecho necessário para satisfazer integralmente o critério de resposta. O resultado mais expressivo foi observado nos itens classificados como difíceis, para os quais o módulo RAG atingiu *Hit@6* de 95,7%, sugerindo potencial utilidade em cenários menos rotineiros e com maior especificidade de protocolo.

O módulo de privacidade não apresentou vazamento no conjunto sintético de 76 entidades avaliadas, embora esse resultado não substitua testes com fala espontânea, abreviações, erros de transcrição e maior variação linguística. A latência média de 15,59 segundos no fluxo local com RAG evidencia que a inferência local e os requisitos de hardware ainda limitam a adoção de baixo custo em produção. Por fim, a revisão humana obrigatória foi validada como restrição de projeto, pois os resultados reforçam que o sistema deve permanecer assistivo, auditável e não autônomo. A aprovação de quatro dos cinco casos funcionais do roteiro (GT01-GT05) indica coerência funcional inicial, enquanto a falha no GT05 evidencia a necessidade de barreiras de escopo antes da geração via LLM.

Como contribuição, o estudo entrega uma arquitetura replicável, um fluxo de privacidade alinhado aos princípios da LGPD e um benchmark inicial reproduzível para avaliação técnica de recuperação, geração, mascaramento de PII, escopo e latência em documentos de pré-natal. Os resultados evidenciam os trade-offs entre execução local, custo computacional e segurança operacional, indicando que avanços em modelos, quantização, aceleração em hardware e técnicas de RAG podem tornar esse tipo de sistema mais viável em ambientes reais.

CUIDADOS ÉTICOS

Os códigos e dados utilizados neste estudo, disponíveis para uso não comercial, serão disponibilizados após a aceitação do artigo em: «repositório GitHub do autor principal – anonimizado devido ao processo double-blind review».

Este trabalho foi concebido com base em princípios de uso responsável de Inteligência Artificial, com especial atenção às diretrizes da Lei Geral de Proteção de Dados (Lei nº 13.709/2018 – LGPD). O sistema proposto adota processamento local (*on-premise*), descarte imediato de áudio após transcrição e um *gateway* de anonimização responsável por detectar e mascarar informações pessoalmente

identificáveis (PII) antes da inferência pelo modelo, reduzindo a exposição de dados sensíveis.

Atende à Resolução CNS nº 510/2016. O protótipo não utiliza dados clínicos reais nem envolve participantes humanos, baseando-se exclusivamente em cenários sintéticos para avaliação experimental. Dessa forma, o estudo não se enquadra como pesquisa envolvendo seres humanos segundo a Resolução CNS nº 510/2016, não sendo necessária submissão ao Comitê de Ética em Pesquisa. Ainda assim, o desenho do sistema considera riscos potenciais associados ao contexto clínico, adotando mecanismos de mitigação como validação humana obrigatória (*human-in-the-loop*) e ausência de autonomia decisória do modelo.

Do ponto de vista ético, o sistema é explicitamente posicionado como ferramenta assistiva, não substituindo o julgamento clínico profissional. Para mitigar riscos de uso indevido ou respostas fora do escopo do pré-natal, são previstas salvaguardas adicionais, como restrições de domínio, possibilidade de recusa a consultas inadequadas e necessidade de validação manual antes da persistência de qualquer informação no prontuário.

Por fim, reconhece-se que, embora o protótipo demonstre viabilidade técnica, sua adoção em ambientes reais requer validação clínica, avaliação ética adicional e conformidade com regulamentações institucionais e profissionais aplicáveis.

Durante a preparação do texto, foi utilizado o modelo Gemini 3.1 Pro (Google, 04/2026) para revisão gramatical e refinamento de clareza. A ferramenta não foi utilizada para geração de resultados experimentais, análise de resultados ou compartilhamento de dados sensíveis. Todo o conteúdo obtido de forma automatizada foi revisado e editado conforme necessário, sob total responsabilidade dos autores.

REFERÊNCIAS

- [1] Lameck Mbangula Amugongo, Pietro Mascheroni, Steven Brooks, Stefan Doering, and Jan Seidel. 2025. Retrieval augmented generation for large language models in healthcare: A systematic review. *PLOS Digital Health* 4, 6 (2025), e0000877.
- [2] APXML. 2024. VRAM Calculator for LLMs. <https://apxml.com/tools/vram-calculator>. Acesso em: 20 abr. 2026.
- [3] Elham Asgari, Nina Montaña-Brown, Magda Dubois, Saleh Khalil, Jasmine Balloch, Joshua Au Yeung, and Dominic Pimenta. 2025. A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation. *NPJ digital medicine* 8, 1 (2025), 274.
- [4] L. S. Bernardes et al. 2022. Facial expressions of acute pain in 23-week fetus. *Ultrasound in Obstetrics & Gynecology* 59, 3 (2022), 394–395. doi:10.1002/uog.23709
- [5] Brasil. 2018. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 20 abr. 2026.
- [6] Brasil. Ministério da Saúde. 2010. *Gestão de Alto Risco: Manual Técnico* (5. ed. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/gestacao_alto_risco.pdf. Acesso em: 5 fev. 2026.
- [7] Brasil. Ministério da Saúde. 2012. *Cadernos de Atenção Básica: Atenção ao Pré-natal de Baixo Risco* (1. ed. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/cadernos_atencao_basica_32_prenatal.pdf. Acesso em: 5 fev. 2026.
- [8] Brasil. Ministério da Saúde. 2012. *Manual Técnico Gestão de Alto Risco* (5. ed. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/manual_tecnico_gestacao_alto_risco.pdf. Acesso em: 5 fev. 2026.
- [9] Brasil. Ministério da Saúde. 2022. *Manual de Gestão de Alto Risco* (1. ed. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/manual_gestacao_alto_risco.pdf. Acesso em: 5 fev. 2026.
- [10] Brasil. Ministério da Saúde. 2024. *Caderneta da Gestante* (8. ed. rev. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/caderneta_gestante_8ed_rev.pdf. Acesso em: 5 fev. 2026.
- [11] Brasil. Ministério da Saúde. 2025. *Guia do Pré-natal do Parceiro para Profissionais de Saúde* (2. ed. ed.). Brasília, DF. https://bvsms.saude.gov.br/bvs/publicacoes/guia_pre_natal_profissionais_saude%E2%80%93932ed.pdf. Acesso em: 5 fev. 2026.

- [12] Brasil. Sistema Único de Saúde. 2018. *Ficha Pré-natal: Acolhimento e Identificação*. Jaguarão, RS. <https://www.jaguara.rs.gov.br/wp-content/uploads/2018/05/ANEXO-1D.pdf> Acesso em: 5 fev. 2026.
- [13] Federico Cabitza, Davide Ciucci, Gabriella Pasi, and Marco Viviani. 2022. Responsible AI in Healthcare. *arXiv preprint* (2022). arXiv:2203.03616v1.
- [14] Jaime G. Carbonell and Jade Goldstein. 1998. The Use of MMR, Diversity-Based Reranking for Reordering Documents and Producing Summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*. 335–336. doi:10.1145/290941.291025
- [15] Kang Chen, Xiuzhe Zhou, Yuanguo Lin, Shibo Feng, Li Shen, and Pengcheng Wu. 2025. A survey on privacy risks and protection in large language models. *Journal of King Saud University Computer and Information Sciences* 37, 7 (2025), 163.
- [16] Maribel Cifuentes, Melinda Davis, Doug Fernald, Rose Gunn, Perry Dickinson, and Deborah J Cohen. 2015. Electronic health record challenges, workarounds, and solutions observed in practices integrating behavioral health and primary care. *The Journal of the American Board of Family Medicine* 28, Supplement 1 (2015), S63–S72.
- [17] Jan Clusmann, Fiona R. Kolbinger, Hannah S. Muti, Zunamys I. Carrero, Jens-Niklas Eckardt, Nektarios G. Laleh, Christian M. L. Löffler, Sophie C. Muti, Philip Quirke, Daniel Truhn, et al. 2023. The future landscape of large language models in medicine. *Communications Medicine* 3, 1 (2023), 141.
- [18] Paul Hager, Friederike Jungmann, Robbie Holland, Kunal Bhagat, Inga Hubrecht, Manuel Knauer, Jakob Vielhauer, Marcus Makowski, Rickmer Braren, Georgios Kaissis, et al. 2024. Evaluation and mitigation of the limitations of large language models in clinical decision-making. *Nature medicine* 30, 9 (2024), 2613–2622.
- [19] Yu He Ke, Liyuan Jin, Kabilan Elangovan, Hairil Rizal Abdullah, Nan Liu, Alex Tiong Heng Sia, Chai Rick Soh, Joshua Yi Min Tung, Jasmine Chiat Ling Ong, Chang-Fu Kuo, et al. 2025. Retrieval augmented generation for 10 large language models and its generalizability in assessing medical fitness. *npj Digital Medicine* 8, 1 (2025), 187.
- [20] Clemens Scott Kruse, Rishi Goswamy, Yesha Jayendrakumar Raval, and Sarah Marawi. 2016. Challenges and opportunities of big data in health care: a systematic review. *JMIR medical informatics* 4, 4 (2016), e5359.
- [21] Ruy Laurenti et al. 2010. Mortes maternas: revisão do fator de correção para os dados oficiais. *Revista Brasileira de Epidemiologia* 13 (2010), 1–11.
- [22] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, Vol. 33. 9459–9474.
- [23] LLMBase. 2026. LLM Benchmark Comparator. <https://llmbase.ai/compare/qwen3-14b-instruct-reasoning,qwen3-5-9b/>. Acesso em: 20 abr. 2026.
- [24] Ivan Lopez, Akshay Swaminathan, Karthik Vedula, Sanjana Narayanan, Fateme Nateghi Haredasht, Stephen P Ma, April S Liang, Steven Tate, Manoj Maddali, Robert Joseph Gallo, et al. 2025. Clinical entity augmented retrieval for clinical information extraction. *NPJ digital medicine* 8, 1 (2025), 45.
- [25] Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khoshabi, and Hannaneh Hajishirzi. 2023. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. In *Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: Long papers)*. 9802–9822.
- [26] Microsoft. 2026. Criar e executar avaliações de agentes no Microsoft Copilot Studio. <https://learn.microsoft.com/pt-br/microsoft-copilot-studio/analytics-agent-evaluation-create>. Acesso em: 25 mar. 2026.
- [27] Amanda J Moy, Mollie Hobensack, Kyle Marshall, David K Vawdrey, Eugene Y Kim, Kenrick D Cato, and Sarah C Rossetti. 2023. Understanding the perceived role of electronic health records and workflow fragmentation on clinician documentation burden in emergency departments. *Journal of the American Medical Informatics Association* 30, 5 (2023), 797–808.
- [28] Amanda J Moy, Jessica M Schwartz, RuiJun Chen, Shirin Sadri, Eugene Lucas, Kenrick D Cato, and Sarah Collins Rossetti. 2021. Measurement of clinical documentation burden among physicians and nurses using electronic health records: a scoping review. *Journal of the American Medical Informatics Association* 28, 5 (2021), 998–1008.
- [29] Aryelly Dayane da Silva Nunes, Ana Edimilda Amador, Ana Patrícia de Queiroz Medeiros Dantas, Ulicélia Nascimento de Azevedo, and Isabelle Ribeiro Barbosa. 2017. Acesso à assistência pré-natal no Brasil: análise dos dados da Pesquisa Nacional de Saúde. *Revista Brasileira em Promoção da Saúde* 30, 3 (set. 2017). doi:10.5020/18061230.2017.6158
- [30] OpenMed Science. 2026. OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1: Portuguese PII Detection Model. <https://huggingface.co/OpenMed/OpenMed-PII-Portuguese-SnowflakeMed-Large-568M-v1>
- [31] OWASP GenAI Security Project. 2025. OWASP Top 10 for Large Language Model Applications. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>. Versão 2025 (v2.0); CC BY-SA 4.0. Acesso em: 20 abr. 2026.
- [32] Qwen Team. 2026. Qwen3.5-9B Model Card. <https://huggingface.co/Qwen/Qwen3.5-9B>. Acesso em: 20 abr. 2026.
- [33] Pranav Rajpurkar, Emily Chen, Oishi Banerjee, and Eric J. Topol. 2022. AI in health and medicine. *Nature Medicine* 28, 1 (2022), 31–38.
- [34] Removido para revisão anônima. 2022. Removido para revisão anônima. Trabalho anterior removido para revisão anônima.
- [35] Removido para revisão anônima. 2025. Removido para revisão anônima. Trabalho anterior removido para revisão anônima.
- [36] A. S. Rosa et al. 2020. VP21.09: Assessment of early acute pain in the fetus before 24 weeks pregnancy. *Ultrasound in Obstetrics & Gynecology* 56, S1 (2020), 146–146. doi:10.1002/uog.22666
- [37] SES-MG. 2024. *Guia de Atenção à Saúde da Gestante: Critérios para Estratificação de Acompanhamento da Gestante* (1. ed. ed.). Belo Horizonte, MG. <https://www.saude.mg.gov.br/wp-content/uploads/2025/01/12-11-Estratificacao-de-Risco-final-1.pdf> Acesso em: 5 fev. 2026.
- [38] SES-SC. 2014. *Atualização em Pré-natal para Profissionais da Atenção Básica* (1. ed. ed.). Florianópolis, SC. <https://saude.sc.gov.br/index.php/pt/redes-de-atencao-a-saude/rede-cegonha/acervo-e-e-book/manual-oficina-de-atualizacao-em-pre-natal-para-profissionais-da-atencao-basica/download> Acesso em: 5 fev. 2026.
- [39] Chaitanya Sharma. 2025. Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers. *arXiv preprint arXiv:2506.00054* (2025). doi:10.48550/arXiv.2506.00054 Preprint.
- [40] Ben Shneiderman. 2021. Responsible AI: Bridging from Ethics to Practice. *Commun. ACM* 64, 8 (2021), 32–35. doi:10.1145/3445973
- [41] SYSTRAN. 2026. faster-whisper: Faster Whisper Transcription with CTranslate2. <https://github.com/SYSTRAN/faster-whisper>. Acesso em: 28 jun. 2026.
- [42] Thomas Yu Chow Tam, Sonish Sivarajkumar, Sumit Kapoor, Alisa V Stolyar, Katelyn Polanska, Karleigh R McCarthy, Hunter Osterhoudt, Xizhi Wu, Shyam Visweswaran, Sunyang Fu, et al. 2024. A framework for human evaluation of large language models in healthcare derived from literature review. *NPJ digital medicine* 7, 1 (2024), 258.
- [43] Akihiko Wada, Yuya Tanaka, Mitsuo Nishizawa, Akira Yamamoto, Toshiaki Akashi, Akifumi Hagiwara, Yayoi Hayakawa, Junko Kikuta, Keigo Shimoji, Katsuhiko Sano, et al. 2025. Retrieval-augmented generation elevates local LLM quality in radiology contrast media consultation. *NPJ Digital Medicine* 8, 1 (2025), 395.
- [44] Krzysztof Wolk. 2025. Evaluating Retrieval-Augmented Generation Variants for Clinical Decision Support: Hallucination Mitigation and Secure On-Premises Deployment. *Electronics* 14, 21 (2025), 4227.
- [45] Yifan Yao, Jinhao Duan, Kaidi Xu, Yuanfang Cai, Zhibo Sun, and Yue Zhang. 2024. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly. *High-Confidence Computing* 4, 2 (2024), 100211.